

文章编号:1009-6094(2023)11-4002-11

基于多生理信号融合的 疲劳驾驶检测研究*

龚淑娟¹,赵永翔²,黄德明³

(1 泉州经贸职业技术学院管理系,福建泉州 362000;

2 福州大学经济与管理学院,福州 350108;

3. 国网泉州供电公司,福建泉州 362000)

摘要:为减少交通事故,保障道路交通安全,提出一种能更加有效地检测驾驶人驾驶状态的方法。通过对疲劳状态进行等级划分,利用脉搏波信号(Photoplethysmographic signal, PPG)以及皮肤电反应信号(Galvanic Skin Response, GSR),实现多种生理信号融合,进而构建驾驶人的驾驶疲劳状态数据库。根据采集数据结合主观评测分析驾驶人状态变化规律,选取有效指标进行分析比较,以探究各个指标与疲劳程度的变化趋势。依据状态变化规律和特征,结合主观评测,分析驾驶人的疲劳状态。同时,设定疲劳状态等级,分为清醒、轻度疲劳和重度疲劳状态,构建隐马尔可夫(Hidden Markov Model, HMM)驾驶疲劳水平分级的疲劳评估模型。测试结果显示:训练后的HMM疲劳检测模型准确率为90%。

关键词:安全工程;疲劳驾驶;生理指标;多特征融合;隐含马尔科夫模型;疲劳分级

中图分类号:X951 **文献标志码:**A

DOI: 10.13637/j.issn.1009-6094.2022.1792

0 引言

道路交通安全涉及千家万户,事关国之大者。近年来,我国国民经济和社会发展得益于迅速发展的高速公路基础建设,交通安全也引起社会各界关注。驾驶人在高速公路上长时间驾驶,因道路情况单调、景观单一而无聊或注意力分散,将有嗜睡或睡着的风险。疲劳的驾驶人常会产生分神、精神颓废、反应迟钝和判断能力下降等消极行为,在撞车前无法采取正确的行动以避免事故发生。因此,由驾驶人困倦而引起的事故比其他类型事故后果更为严重,会导致财产损失及极大的人身安全威胁。据美国一项调查显示,在机动车事故中有1%~3%是由

驾驶人警觉性降低造成的,近96%的事故是由驾驶人严重缺乏睡眠造成的,3%的事故涉及大型卡车驾驶人^[1]。因此,对驾驶人的疲劳驾驶进行检测具有重大意义。

2003年,Thiffault等^[2]最先针对不同的道路情况展开了疲劳研究。结果显示,与弯道相比,驾驶人在直路(如高速公路)上对疲劳的敏感性更高。这是因为高速公路路况好,驾驶环境单调,操作简单,易导致被动疲劳。疲劳驾驶容易引起驾驶人驾驶行为和警觉性变化,随疲劳程度的增加,反应时间延长^[3]。Matthews等^[4]通过信号检测和行人检测显示,驾驶人在疲劳状态下驾驶时会对驾驶安全造成严重威胁。因此,疲劳对驾驶性能的不利影响突出了及时进行疲劳检测的重要性。多年来,大量专家学者主要以2个方向进行疲劳检测。一是疲劳检测算法,利用计算机建模等方式实现驾驶人的疲劳检测。1982年,Borbély^[5]开创性地利用昼夜节律过程和稳态过程的相互作用,建立了双过程模型,这是预测疲劳性能和疲劳水平方面最早的模型之一。此外,还有自然驾驶研究^[6]、判断激发模式(Judging Excitation Mode, JEM)^[7]、空-时特征与人体姿态模型^[8]等。机器学习也被广泛运用于疲劳驾驶研究中,如人工神经网络(Artificial Neural Networks, ANN)^[9]、图形神经网络^[10]、卷积神经网络(Convolutional Neural Networks, CNN)^[11]、贝叶斯结构方程模型(Bayesian Structural Equation Modeling, Bayesian-SEM)^[12]等。二是疲劳检测方法,致力于从各个角度探究疲劳的转变过程。其中,生理信号能够为发现早期疲劳提供指示,并可及时预防事故。生理信号可以分为心脏、大脑、眼睛和皮肤信号。生理信号的变化,例如EEG(Electroencephalography)^[13]、ECG(Electrocardiogram)^[14]、EoG(Electronystagmogram)^[15]和PPG(Photoplethysmography)^[16]是检测疲劳的精确方法。在驾驶中,眨眼持续时间和反应时间与被动疲劳有直接关系^[17]。但在驾驶行为和生理特征表现中,个体差异会对疲劳检测产生一定影响^[18]。冯晓锋^[19]融合了眼、嘴、头部特征进行疲劳检测,一定程度上克服了个体差异。近年来,学者运用了各项车辆相关的指标以判断驾驶人的疲劳状态,例如车辆侧向速度^[20]、转向行为^[21]等。2009年,成波等^[22]首次综合利用眼部特征、方向盘特征及车辆行驶轨迹,克服了单一传感器在疲劳检测中的局限性,提高了疲劳检测准确性,为多指标融合的疲劳检测研究奠定了基础。此后,各界对方向盘转角和PPG

* 收稿日期:2022-08-30

作者简介:龚淑娟,助教,从事物流交通运输研究,6163242501@qq.com;赵永翔(通信作者),教授,博士,从事物联网与智能交通、复杂系统建模与优化领域研究,zhaosanhe@263.net。

基金项目:国家自然科学基金项目(71974033,71942002)

结合^[23]、眼电与脑电融合^[24]等开展了相关研究。

疲劳检测的特征可分为主观报告、生理特征、身体特征、车辆特征和混合特征。通过对这些方法的比较得知,主观报告和生理特征对实时处理的适用性有限,限制了在真实世界驾驶人疲劳检测中的应用。人类可能表现出多种疲劳症状和水平,因此一种特征不能准确地用于疲劳检测。当下,针对各类疲劳检测的指标在检测设备、指标的稳定性以及影响因素方面仍有缺陷。各界都在积极探索研发准确度更高、更便捷的疲劳检测方法。国内外社会各界都期望学术界充分重视并解决这个问题。因此,在长途驾驶过程中,驾驶人是否产生疲劳驾驶以及如何检测驾驶人驾驶疲劳状态、疲劳驾驶的程度,如何更好地使驾驶人维持驾驶警觉以保证安全的相关研究对于物流运输具有重要意义。当前,关于疲劳驾驶的分级评定还未有明确的判定标准,对于疲劳驾驶的程度量化问题还存在一定的探讨空间。

综上,本文将在模拟驾驶状态下对被试者展开接触式检测试验,并根据驾驶人穿戴相关传感器采集驾驶人的生理信号,对疲劳驾驶展开检测,以期构建驾驶人的驾驶疲劳状态数据库,分析归纳驾驶人状态变化规律进而确定疲劳特征。在此基础上,结合主观评测以分析驾驶人的疲劳状态,并对其进行状态等级设定,构建驾驶疲劳水平分级的疲劳评估模型,以期搭建驾驶人危险知觉预测指标体系提供理论基础和现实条件。

1 试验流程

为获取驾驶人在不同驾驶状态下的试验数据,保证数据的真实性和可靠性,选取合适的路段展开模拟驾驶。试验采用的设备包括车辆、生理采集器、红外视频监控采集器(导师及实验室成员共同研发)及笔记本电脑等。

1.1 试验平台搭建

由于真实道路有风险,且疲劳驾驶为违法行为,展开实际道路环境下的疲劳驾驶试验具有较大困难。因此,试验考虑模拟真实的驾驶情况,在模拟驾驶实验室进行疲劳测试试验。实验室环境见图1。试验平台系统以及试验平台的车辆运动模拟系统、传感器、三维视景模拟系统、声响系统均可满足研究需要。

生理记录系统包括硬件采集器及分析软件2部分。其中,硬件采集器能够采集肌电信号(Electromyographic signal, EMG)、PPG、GSR等多种

生理信号数据。硬件采集器的佩戴方式见图2和3。软件部分主要由Python及内置程序组成,能对采集数据进行信号平滑、降噪、叠加、频谱分析等。软件页面见图4。

通过视频摄像头采集器采集驾驶人的面部状态,实时追踪驾驶人的面部变化,并对驾驶人的疲劳状态进行主观分级。试验在获取生理指标数据的同时,记录驾驶人的面部视频。

1.2 试验设计

试验被试者对象共24名,其中男性13人、女性



(a) 前方视角



(b) 后方视角

图1 模拟驾驶平台整体环境

Fig. 1 Overall environment of the driving simulation platform



图2 采集器佩戴方式

Fig. 2 Wear mode of collector

11 人,年龄为 20 ~ 35 岁,有驾驶证,1 ~ 5 a 驾龄,且从未有过与疲劳驾驶相关的交通事故记录。

被试者均在同一段场景进行模拟驾驶试验。被试者沿着高速公路行驶约 60 min 后驶离,再行驶 5 min 到达城市,最后在城市环境中行驶约 3 min。在高速公路的大部分路段没有车辆。行驶至约 2/3 路程时,29 辆汽车从公路右侧出现,1 ~ 3 km 后消失。交通流量的突然增加旨在改变驾驶人的困倦程度。

疲劳是介于警觉和睡眠之间的一种中间状态。试验过程中主观疲劳等级根据卡罗林斯卡嗜睡表 (Karolinska Sleepiness Scale, KSS) 和斯坦福嗜睡表 (Stanford Sleepiness Scale, SSS) 进行划分。结合试验目的将疲劳等级划分为主观可评判的 3 个等级,见表 1。

1.3 试验过程

(1)参与者接受短期培训,学习测试目标、过程




图 3 采集器佩戴示意图

Fig. 3 Wear schematic diagram of a collector

和任务,以减轻心理压力。调整车辆座椅和车轮位置,确保驾驶人处于最舒适的驾驶位置,调整所有的试验设备。

(2)开启设备,采集驾驶人平静且清醒状态下的数据。在模拟驾驶 10 min 后,正式进入试验环节,每次试验时间为 100 ~ 150 min。当被试者进入重度疲劳状态后,继续向前行驶 10 min 左右,结束试验。期间连续记录驾驶人的生理指标,5 min 记录 1 次驾驶人的主观疲劳等级。

(3)结束试验,储存数据,而后进行下一位被试者驾驶试验。其中,数据在测验前后均需收集,包括疲劳状态和非疲劳状态样本。试验流程见图 5。

2 疲劳特征提取及分析

2.1 主观疲劳评价

根据试验中判定的驾驶人主观疲劳等级可得到驾驶人疲劳状态分布,部分被试者的疲劳状态分布见图 6。每位被试者由清醒进入疲劳状态的时间不

表 1 主观疲劳分级表

Table 1 Subjective fatigue rating table

疲劳等级	描述
1	清醒状态,注意力高度集中,警觉性强,反应灵敏
2	意识稍模糊,注意力不够集中,警觉性降低,反应速度有所减慢
3	意识模糊,注意力不集中,面部出现打哈欠、眨眼速度慢等疲劳特征,反应迟钝,极易进入睡眠状态

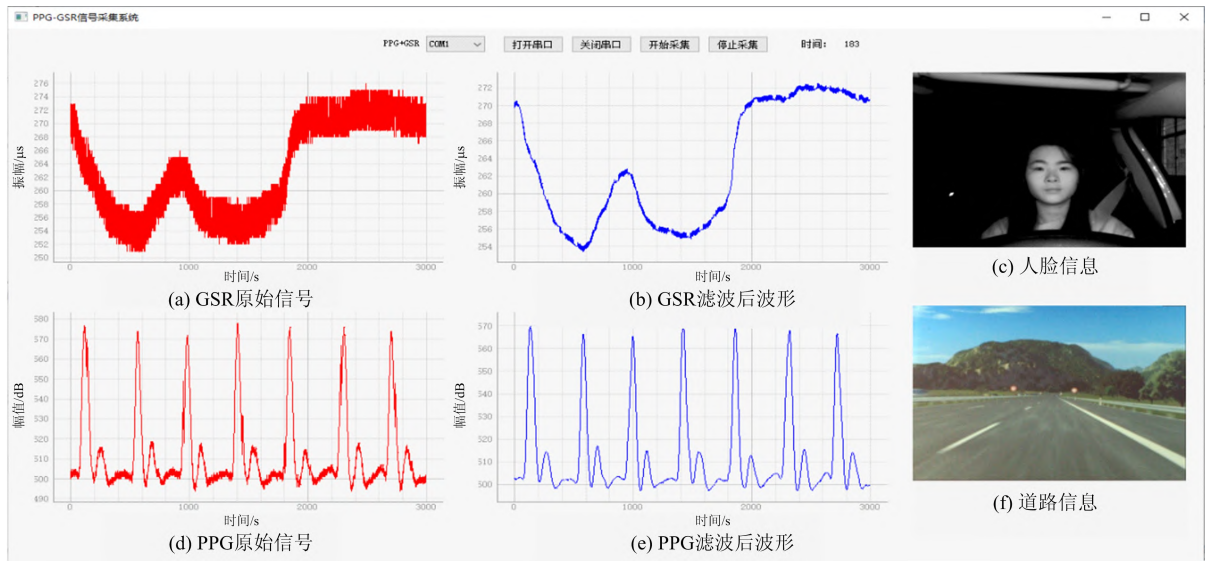


图 4 生理数据采集页面

Fig. 4 Page of physiological data collection

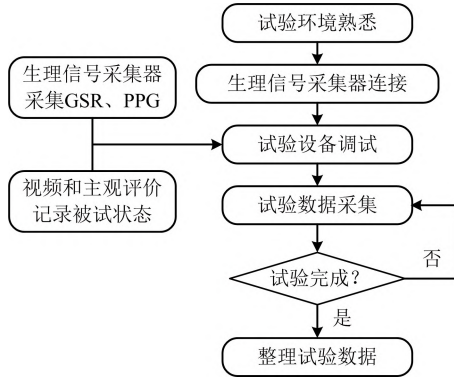


图5 疲劳驾驶检测试验流程图

Fig. 5 Flow chart of fatigue driving test experiment




图6 主观评价驾驶人疲劳状态分布图

Fig. 6 Distribution chart of subjective evaluation of driver's fatigue state

同,最短 15 min,最长可达 50 min。除个体差异外,被试者在试验前一天晚上的睡眠质量以及日常作息习惯对试验当天的表现会产生一定的影响。

根据主观评价疲劳分布,结合疲劳驾驶试验获得的各阶段生理数据,可初步完成疲劳识别分级模型数据库的构建工作,并得到预处理后的试验数据。

2.2 HRV 特征提取

通过 PPG 信号指标分析心率变异性(Heart Rate Variability, HRV)是一种常见的疲劳检测指标。HRV 指心率的逐拍变化,每个心动周期都会产生心电图波,称为 P、Q、R、S 和 T,代表心跳的不同阶段。R-R 间期是指心电图从一个 QRS 复合波的峰值到下一个峰值的间隔。HRV 分析显示了自主神经系统调节功能和平衡状态的重要信息。用时域和频域的方法分析心率在短期内的变化,可得到心率的平衡度和活动度。研究从 HRV 时域、频域以及非线性特征着手,检测驾驶员睡意。

采用小波包分解与重构。考虑 PPG 信号中 HRV 频域最高值,和 Daubechies 系列的小波中与 PPG 信号的波形相似性,选用 db4 小波作为小波函数,得到 PPG 信号的波峰。将每个序列波峰点 P_i 的前后两项相减 $P_i - P_{i-1}$,得到 RRI 序列 P_R 。

2.2.1 时域特征

时域特征分析从统计学角度对 HRV 进行分析,是最常见的方法。

R-R 间期均值(Mean, M)表达见式(1)。

$$M = \overline{T_{RR}} = \sum_{i=0}^N \frac{T_{RR,i}}{N} \quad (1)$$

式中 $\overline{T_{RR}}$ 为 R-R 间期均值,ms; N 为心跳间期数; $T_{RR,i}$ 表示第 i 个 R-R 间期,ms。

相邻正常的 R-R 间期(NN)差大于 50 ms 的个数占正常心跳个数的百分比 p_{NN50} (%) 计算见式(2)。

$$p_{NN50} = \frac{n_{NN50}}{n_{NN}} \times 100\% \quad (2)$$

式中 n_{NN} 表示相邻正常心跳的间期数, n_{NN50} 表示 NN 之差大于 50 ms 的间期数。

差均方根(Root Mean Square of Successive Differences, RMSSD) R_{MSSD} 计算见式(3)。

$$R_{MSSD} = \sqrt{\frac{\sum_{i=1}^{N-1} (T_{RR,i+1} - T_{RR,i})^2}{N-1}} \quad (3)$$

NN 间期标准差(Standard Deviation of NN Intervals, SDNN) S_{DNN} 计算见式(4)。

$$S_{DNN} = \sqrt{\frac{\sum_{i=0}^N (T_{RR,i} - \overline{T_{RR}})^2}{N-1}} \quad (4)$$

将被试者数据以 5 min 为时间窗进行整理,通过 Python 计算 M 、 p_{NN50} 、 S_{DNN} 、 R_{MSSD} 见图 7。 M 、 p_{NN50} 指标随着驾驶时间的延长,被试者的疲劳程度逐步增加,呈现下降的趋势。然而 SDNN、RMSSD 则相反,在疲劳状态下,其数值比清醒状态下更大。

2.2.2 频域特征

频域分析能够表征信号各频率分量的分布情况,从而对信号信息集中在高低频中的某频域进行指示。利用频域分析 RRI 频谱,能够很好地反映迷走神经和交感神经活动的变化。

极低频功率(Very Low Frequency, VLF, 频段 0.003 ~ 0.04 Hz)表达见式(5)。

$$a_{VLF} = \int_{f_1}^{f_2} p_{PSD}(f) df \quad (5)$$

式中 a_{VLF} 为极低频功率, W; $p_{PSD}(f)$ 为信号的功




图7 时域特征变化趋势

Fig. 7 Change trend of time domain characteristics

率能量与频率关系的物理量; f 为频率, Hz, 取 $0 \sim 0.5$ Hz。

低频功率 (low Frequency power, LF, 频段 $0.04 \sim 0.15$ Hz) 表达见式(6)。

$$a_{LF} = \int_{f_1}^{f_2} p_{PSD}(f) df \quad (6)$$

式中 a_{LF} 为低频功率, W。

高频功率 (High Frequency power, HF, 频段 $0.15 \sim 0.4$ Hz) 表达见式(7)。

$$a_{HF} = \int_{f_1}^{f_2} p_{PSD}(f) df \quad (7)$$

式中 a_{HF} 为高频功率, W。

总功率 (Total Power, TP, 频段 ≤ 0.4 Hz) 表达见式(8)。

$$a_{TF} = a_{VLF} + a_{LF} + a_{HF} \quad (8)$$

式中 a_{TF} 为总功率, W。

低高频功率比 (LF/HF, R) 表达见式(9)。

$$R = a_{LF} / a_{HF} \quad (9)$$

将试验数据按 5 min 进行分割, 以计算被试者的频域指标。以被试 4 为例, 分别截取不同程度疲劳状态下时段的 PPG 生理数据, 通过 Python 计算得出该时段的非参数功率谱密度 (Power Spectrum Diagram, PSD) 见图 8。

由图 8 可知, 在清醒状态下, HRV 的功率谱主

要集中在极低频, 低频和高频分布较少。但随着疲劳程度的加深, HRV 的功率谱能量逐渐向右移动, 且在轻度疲劳向重度疲劳的变化过程中, 转移速度加快。

抽取 3 位被试每分钟的 LF/HF 各 150 个数据点, 其变化趋势见图 9。

从图 9 可以看出, 3 名被试者的 LF/HF 总体的变化趋势: 随着驾驶时间的延长, 当被试者进入疲劳状态时, LF/HF 逐渐下降, LF/HF 变化敏感度较高, 会产生一定的波动。尤其是被试疲劳状态减轻时, LF/HF 会有小范围的上升并保持, 当被试对象再次进入疲劳状态时又开始下降。

2.2.3 非线性指标

常见的 HRV 非线性指标 C_0 复杂度适用于小样本计算, 且运算速度较快。考虑本文的样本容量小以及生理数据庞大, 因此选用 C_0 复杂度以作为 HRV 的非线性特征指标。 C_0 复杂度 (C_0) 是完整时间序列的测度平方和 A_1 与随机部分时间序列的测度平方和 A_0 的比值, 即

$$C_0(r) = \frac{A_1}{A_0} = \frac{\sum_{n=0}^{N-1} |x(n) - \tilde{x}(n)|^2}{\sum_{n=0}^{N-1} |x(n)|^2} \quad (10)$$

式中 $x(n)$ 为一个长度为 N 的时间序列傅里叶变换后再经傅里叶逆变换得到的序列。

将所有被试者的 PPG 数据经处理后得到 HRV 数据以作为 C_0 复杂度样本。抽取 3 名被试样本数据,以 5 min 为时间窗,延迟 1 min 为滑动窗口,4 min 的数据重复计算得到 C_0 复杂度序列,并对序列

求均值,见图 10。

虽然 HRV 的 C_0 复杂度在部分时间内存在上下波动的现象,但总体而言,随着驾驶时间的增加 C_0 复杂度呈下降的趋势。

2.3 GSR 指标分析

通过采集器提取以 30 s 为时间窗口,30 s 为滑动窗口的数据,并不同疲劳状态下驾驶人的 GSR 数据变化情况,见图 11。GSR 数据是有规律的、高低起伏的、循环的生理数据,但随着驾驶时间的延长,GSR 数值整体呈上升趋势。

GSR 信号由于易受个体差异性影响,因此常用的指标主要为非线性指标。采用和 HRV 信号相同的处理方法,获得 GSR 信号的样本熵(SampEn),见图 12。

由图 12 可以发现,随着驾驶时间的延长,驾驶人的状态由清醒进入疲劳状态的过程中,GSR 信号的 SampEn 逐渐下降,且波动幅度变小。试验后期驾驶人进入重度疲劳状态时,波动幅度会因人而异,变化有大有小。

2.4 指标优选

选取合适的特征指标作为疲劳驾驶检测模型的检测指标,从时间序列信息中提取有效的疲劳特征

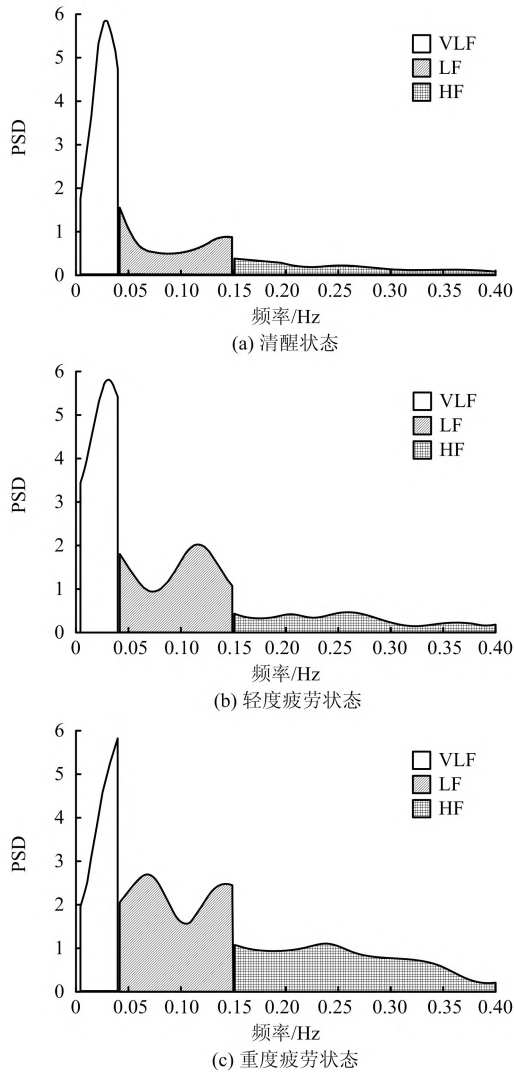


图 8 不同疲劳状态下频域指标功率频谱图

Fig. 8 PSD of frequency domain index under different fatigue states




图 9 LF/HF 变化趋势

Fig. 9 Trends of LF/HF




图 10 HRV 信号的 C_0 复杂度变化趋势

Fig. 10 Trend of C_0 complexity of HRV signal




图 11 GSR 的变化趋势

Fig. 11 Trends of GSR




图12 GSR信号SampEn变化趋势图

Fig. 12 Trend of SampEn of GSR signal

对其解析,并将原始的行为测量空间转换成疲劳驾驶模式下的分类空间。以收集的5 min清醒状态下各类指标数据的均值为基准,将轻度疲劳和重度疲劳状态下的数据减去均值基准,以对所有指标进行分析优选。

对指标数据进行共线性分析和假设检验以完成指标优选。使用皮尔逊相关系数(Pearson Correlation Coefficient, PCCs)作为冗余性分析指标,对指标进行共线性分析,排除引起共线性的变量。结果显示,Mean和其他指标都具有较强的相关性,最高达到0.999。SDNN与RMSSD的相关系数为1。NN50与 p_{NN50} 强相关。TP、VLF、LF、HF与LF/HF之间都存在相关性。样本熵、关联维数D2具有较强的相关性。 C_0 复杂度指标与样本熵、关联维数D2不具有相关性。但斯皮尔曼系数显示,样本熵、关联维数D2与 C_0 复杂度指标互有高相关性。重共线性分析结果显示,SDNN、RMSSD存在多重共线性关系,LF、HF和TP3者具有共线性关系,样本熵、关联维数D2存在共线性关系。

采用Mann-Whitney U test检验驾驶人在3个不同水平状态下各指标的统计差异性。通过

SPSS计算分析得到清醒状态下和重度疲劳状态下的Mann-Whitney U test检验结果显示,HRV时域指标中,SDNN在不同的疲劳状态下变化最明显。频域指标的差别也较大,VLF、LF、HF3者反映单项神经活性,LF/HF能够综合反映交感神经与迷走神经的变化关系。TP虽然能够反映人类自主神经与心脏的负荷能力,但其与SDNN的生理特性一致性很强。因此,在频域指标中选择LF/HF指标进行评估。在非线性指标中, C_0 复杂度随被试者的疲劳状态加重的变化规律较其他指标更为明显。

本文最终选定HRV信号的SDNN、LF/HF、 C_0 复杂度,GSR信号的样本熵指标作为疲劳驾驶检测模型的特征指标。

3 疲劳检测模型构建

驾驶人的驾驶状态变化是2种随机变化的过程,直接观测只能获得驾驶人具象化的特征,如生理指标、动作、面部表情和驾驶行为等,将此类特征作为观测状态。无法直接测量、识别的疲劳状态为隐含状态。HMM要求隐含状态即隐变量是离散的,对发射矩阵无要求。因此,本文基于HMM构建驾驶人疲劳状态识别与分级模型。

3.1 HMM建模

HMM可以通过给定的模型参数和观测序列,预测与观测序列对应的隐含序列。本文可以利用HMM预测驾驶人驾驶时的疲劳状态,以疲劳驾驶试验得到的数据样本聚类类别为观测状态,驾驶人的疲劳等级为隐含状态。本文的隐含状态数为3,包括清醒、轻度疲劳和重度疲劳。建立的模型转移关系见图13。其中, H_1 表示清醒, H_2 表示轻度疲劳, H_3 表示重度疲劳。 a_{ij} 为 t 时刻到 $t+1$ 时刻各状态之间的转移概率,即表示 t 时刻处于 i 状态到 $t+1$ 时刻为 j 状态的转移概率。

3.2 HMM观测指标状态数分析

根据试验数据构建疲劳状态数据库,确定疲劳分级指标:HRV信号的SDNN、LF/HF、 C_0 复杂度指标,GSR信号的SampEn指标,分别用 I_1 、 I_2 、 I_3 、 I_4 表示,即模型观测状态 $I = (I_1, I_2, I_3, I_4)^T$ 。HMM的观测指标要求为时间序列,需要对疲劳特征指标进行聚类分析简化模型。参考主观评测疲劳中的KSS标准,设置观测指标状态数为2~9类,分别代入算法中计算。选取最优的聚类效果数作为研究模型的观测状态数。参考文献[25-26]及论坛(CSDN等)

常用标准,本文取模糊因子 $m = 2$ 。以 5 类为例进行 FCM(Fuzzy C - Means)分析与对比观察,目标函数在进行迭代 5 次时开始收敛,逐渐趋向于 1 280 916.56 水平。

采用混合 F 统计量(F_{mixed})确定聚类数。通过运算得到观测指标不同聚类数的 F_{mixed} ,即聚类有效性的评价结果,见图 14。当聚类数为 4 时, F_{mixed} 最大,因此选择 4 为最优的聚类数,即模型最优观测指标状态数。

3.3 模型构建

一个完整的 HMM 由隐含状态、观测状态以及各项参数组成,隐含状态数与各个隐含状态之间的转移关系决定了模型的结构类型。




图 13 模型转移关系示意图

Fig. 13 Schematic diagram of the transfer relationship of the model




图 14 不同聚类数的 F_{mixed}

Fig. 14 Value of F_{mixed} with different cluster numbers

3.3.1 模型训练

HMM 的学习过程即参数训练过程,主要为给定观测序列,并通过算法调整模型的参数估计模型参数,以使该模型下的观测状态序列的条件概率 $P(Y|Q)$ 尽可能最大。本文采用了专为求解 HMM 中隐含状态参数而设计的 BW(Baum-Welch)算法。

本文设定初始状态概率向量 $\pi_0 = (0.75, 0.16, 0.09)$ 。初始化状态转移概率矩阵 A_0 ,初始化观测矩阵 B_0 ,计算见式(11)和(12)。

$$A_0 = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = \begin{pmatrix} 0.8014 & 0.1758 & 0.0228 \\ 0.0631 & 0.8610 & 0.0759 \\ 0.0187 & 0.0759 & 0.9054 \end{pmatrix} \quad (11)$$

$$B_0 = \begin{pmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \\ b_{41} & b_{42} & b_{43} \end{pmatrix} = \begin{pmatrix} 0.9412e-24 & 0.0125 & 0.9858 \\ 0.9412 & 6.9451e-5 & 0.0011 \\ 0.0321 & 0.4551 & 1.9292e-18 \\ 0.0268 & 0.5323 & 0.0132 \end{pmatrix} \quad (12)$$

由此得到 $n = 0$ 时的初始化模型 $\lambda_0 = (\pi_0, A_0, B_0)$ 。进行递推运算,最终得到 3 级隐含状态的转移概率矩阵 A 和观测概率矩阵 B ,各类参数见表 2。

4 疲劳状态预测

给定 $\lambda(\pi, A, B)$ 以及观测数据 $O(o_1, o_2, o_3, \dots, o_T)$,通过 Viterbi 算法程序迭代运算,可生成该观测状态序列可能性最大值的隐含状态序列 likelystate 。对数据库中的剩余的 6 组试验数据进行隐含状态预测,将预测结果与主观标注的驾驶人疲劳状态等级进行对比。

观测序列可通过 FCM 聚类算法获得,以其中 100 个数据点为例,则

表 2 HMM 参数

Table 2 Parameters of HMM

π	A	B
$\begin{pmatrix} 0.254 \\ 0.496 \\ 0.250 \end{pmatrix}$	$\begin{pmatrix} 0.801 & 0.175 & 0.024 \\ 0.063 & 0.861 & 0.076 \\ 0.018 & 0.076 & 0.906 \end{pmatrix}$	$\begin{pmatrix} 5.02e-24 & 0.012 & 0.986 \\ 0.941 & 6.82e-5 & 0.001 \\ 0.032 & 0.455 & 1.41e-18 \\ 0.026 & 0.532 & 0.012 \end{pmatrix}$

1 1 1 1 4 4 4 2 4 4 4 4 4 1 3 3 3 3 3
 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3
 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3
 1 1 1 4 4 4 4 1 1 1 1 1 1 1 3 3 1 1 1
 1 1 1 1 1 4 4 1 4 4 4 1 1 4 4 4 1 1 1 4

经过 Viterbi 算法计算得到隐含状态序列。其中,“1”表示驾驶人处于清醒状态,“2”表示驾驶人处于轻度疲劳状态,“3”表示驾驶人处于重度疲劳状态。对应的 likelystate 序列为

3 3 3 3 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2
 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
 3 3 3 2 2 2 2 3 3 3 3 3 3 3 2 2 3 3 3
 3 3 3 3 3 2 2 2 2 2 2 3 3 2 2 2 3 3 3 2

通过观察驾驶人疲劳状态,根据疲劳状态主观分级标准,主观判断驾驶人疲劳状态。对应的时间序列 states 为

2 3 3 3 2 2 2 1 1 2 2 2 2 2 2 2 2 2 2
 2 2 2 2 2 3 2 2 2 2 2 2 2 2 2 2 2 2 1
 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 3 3
 3 3 3 3 2 2 3 3 3 3 3 3 3 2 2 2 3 3 3
 3 3 3 3 3 3 2 2 2 2 3 3 3 2 2 2 3 3 3 3

从样本的驾驶人状态时间序列可以看出,驾驶人的状态在轻度疲劳和重度疲劳状态之间转换,大部分时间为轻度疲劳状态,数据点中出现的清醒状态是由于试验模拟器的道路场景中出现紧急状况导致驾驶人突然受到刺激而表现出短暂清醒。

对比 HMM 预测序列和主观判断序列可知,模型对驾驶人状态的预测与主观判断结果相近,只存在少数点与判断结果不同。以 100 数据点为例,其中预测正确的点数为 90,预测结果存在偏差的点数为 10,试验的准确率为 90%。为保证试验结果进一步符合客观事实,提升其可靠性,将剩余的 2 873 组试验数据进行疲劳检测模型验证,统计准确率,结果见表 3。结果显示,基于 HMM 算法的驾驶人疲劳预测模型对试验样本的预测与主观判定结果高度吻合,模型具有可行性。

表 3 测试结果

Table 3 Test results

状态	测试总数	正确数	正确率/%
1	2 873	2 532	88. 13
2	2 873	2 618	91. 12
3	2 873	2 453	85. 38

5 结 论

针对交通安全中疲劳驾驶状态检测问题,本文利用驾驶试验室模拟驾驶,借助 Silab 软件记录车辆行为数据,并对 24 名测者进行多点采集生理数据,利用 PPG 获取 HRV 和 GSR 2 种接触式检测采集生理信号。通过处理原始信号得到准确可靠人体的疲劳指示。建立约有 6 000 万条样本数据的疲劳驾驶状态数据库,为建立数学模型奠定了现实基础和数据支撑。从具有代表性的指标,如时域、频域以及非线性指标入手,分析各项指标的在疲劳驾驶过程中的变化趋势,均符合疲劳状态切换下的信号变化规律。基于 HMM 算法,融合优选指标有效实现了对驾驶人驾驶状态的动态识别与疲劳水平定级。测试结果显示模型准确率较高,初步符合预期效果,具有应用价值。

本文为预防疲劳驾驶,搭建驾驶人危险知觉预测指标体系提供了现实条件和理论基础。但各项优选指标仅在现有样本下进行分析对比,因此可能与实际存在差异。在后续的研究中将扩大样本容量,以期进一步优化模型的应用性能。

参考文献 (References):

- [1] SIKANDER G, ANWAR S. Driver fatigue detection systems; a review [J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 20(6): 2339–2352.
- [2] THIFFAULT P, BERGERON J. Monotony of road environment and driver fatigue: a simulator study [J]. Accident Analysis & Prevention, 2003, 35(3): 381–391.
- [3] LIU Y, ZHAO X, WU Y P. Study on the effectiveness of driving fatigue prevention safety facility on grassland highway based on driving simulation [C]//The American Society of Civil Engineers. Proceedings of International Conference on Transportation and Development. Washington: The American Society of Civil Engineers, 2020: 264–274.

- [4] MATTHEWS G, DESMOND P A. Task-induced fatigue states and simulated driving performance [J]. The Quarterly Journal of Experimental Psychology: Section A, 2002, 55(2): 659–686.
- [5] BORBÉLY A A. A two process model of sleep regulation [J]. Human Neurobiology, 1982, 1(3): 195–204.
- [6] ZHANG Q, WU C, ZHANG H. Driving fatigue prediction model considering schedule and circadian rhythm [J]. Journal of Advanced Transportation, 2020, 2020(1): 1–10.
- [7] WANG F, WANG H, ZHOU X, et al. Study on the effect of judgment excitation mode to relieve driving fatigue based on MF–DFA [J]. Brain Sciences, 2022, 12(9): 1199.
- [8] 李泰国, 张天策, 李超, 等. 基于人体姿态空时特征的驾驶员疲劳检测[J]. 交通运输系统工程与信息, 2022, 22(5): 337–344.
- LI T G, ZHANG T C, LI C, et al. Driver fatigue detection based on spatial-temporal features and human body pose [J]. Journal of Transportation Systems Engineering and Information Technology, 2022, 22(5): 337–344.
- [9] MAOR F. Data-driven method for real-time prediction and uncertainty quantification of fatigue failure under stochastic loading using artificial neural networks and Gaussian process regression [J]. International Journal of Fatigue, 2022, 155: 106415.
- [10] LIN Z Q, QIU T R, LIU P, et al. Fatigue driving recognition based on deep learning and graph neural network [J]. Biomedical Signal Processing and Control, 2021, 68: 102598.
- [11] JEON Y, KIM B, BAEK Y. Ensemble CNN to detect drowsy driving with in-vehicle sensor data [J]. Sensors, 2021; 21(7): 2372.
- [12] 邓院昌, 史晨军. 基于贝叶斯结构方程模型的疲劳驾驶行为意图研究[J]. 安全与环境学报, 2019, 19(2): 520–526.
- DENG Y C, SHI C J. Psycho-intentional analysis for the factors leading to fatigue driving based on the Bayesian–SEM [J]. Journal of Safety and Environment, 2019, 19(2): 520–526.
- [13] CHAI R, LING S H, SAN P P, et al. Improving EEG–based driver fatigue classification using sparse-deep belief networks [J]. Frontiers in Neuroscience, 2017, 11: 103–117.
- [14] QIN P C, WANG M N, CHEN Z W. Characteristics of driver fatigue and fatigue-relieving effect of special light belt in extra-long highway tunnel: a real-road driving study [J]. Tunnelling and Underground Space Technology, 2021, 114: 103990.
- [15] JIAO Y Y, DENG Y N, LUO Y, et al. Driver sleepiness detection from EEG and EOG signals using GAN and LSTM networks [J]. Neurocomputing, 2020, 408: 100–111.
- [16] PUSPASARI M A, IRIDIASTADI H, SUTALAKSANA I Z, et al. Ocular indicators as fatigue detection instruments for indonesian drivers [J]. Industrial Engineering & Management Systems, 2019, 18(4): 748–760.
- [17] KÖRBER M, CINGEL A, ZIMMERMANN M, et al. Vigilance decrement and passive fatigue caused by monotony in automated driving [J]. Procedia Manufacturing, 2015, 3: 2403–2409.
- [18] 胥川, 裴赛君, 王雪松. 基于无侵入测量指标的个体差异化驾驶疲劳检测[J]. 中国公路学报, 2016, 29(10): 118–125.
- XU C, PEI S J, WANG X S. Driver drowsiness detection based on non-intrusive metrics considering individual difference [J]. China Journal of Highway and Transport, 2016, 29(10): 118–125.
- [19] 冯晓锋. 基于融合眼嘴头部特征的疲劳驾驶检测方法[J]. 安全与环境学报, 2022, 22(1): 263–270.
- FENG X F. Fatigue driving detection method based on fusion of eye, mouth and head features [J]. Journal of Safety and Environment, 2022, 22(1): 263–270.
- [20] 柴萌. 长途客车驾驶人疲劳状态辨识与预警[D]. 长春: 吉林大学, 2019.
- CHAI M. Identification and early-warning of fatigue state of intercity coach drivers [D]. Changchun: Jilin University, 2019.
- [21] 杨萍茹, 黄勇, 廖龙涛, 等. 基于智能手表的疲劳驾驶监测方法研究[J]. 重庆理工大学学报(自然科学), 2020, 34(12): 170–176.
- YANG P R, HUANG Y, LIAO L T, et al. Research on driver fatigue monitoring method based on smart watch [J]. Journal of Chongqing University of Technology (Natural Science), 2020, 34(12): 170–176.
- [22] 成波, 冯睿嘉, 张伟, 等. 基于多源信息融合的驾驶人疲劳状态监测及预警方法研究[J]. 公路交通科技, 2009, 26(增刊1): 13–18.
- CHENG B, FENG R J, ZHANG W, et al. Driver drowsiness detection and warning system based on multi-source information fusion [J]. Journal of Highway and

- Transportation Research and Development, 2009, 26 (Suppl. 1): 13–18.
- [23] LEE B G, LEE B L, CHUNG W Y. Smartwatch-based driver alertness monitoring with wearable motion and physiological sensor [C]//Engineering in Medicine and Biology Society. Proceedings of 2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC). Milan: Engineering in Medicine and Biology Society, 2015: 6126–6129.
- [24] 徐军莉, 王平, 穆振东. 融合眼动和脑电特征的疲劳驾驶检测研究[J]. 重庆交通大学学报(自然科学版), 2021, 40(12): 7–11.
- XU J L, WANG P, MU Z D. Fatigue driving detection based on eye movement and EEG features[J]. Journal of Chongqing University of Technology (Natural Science), 2021, 40(12): 7–11.
- [25] 陈冉. 基于HMM的驾驶疲劳辨识机理研究[D]. 大连: 大连理工大学, 2020.
- CHEN R. Mechanism research on driver fatigue identification based on HMM [D]. Dalian: Dalian University of Technology, 2020.
- [26] 尉志礼, 胥川, 王雪松, 等. 基于隐马尔可夫模型的无侵入疲劳等级判别[J]. 公路交通科技, 2022, 39(5): 112–121.
- WEI Z L, XU C, WANG X S, et al. Non-intrusive drowsiness level identification based on Hidden Markov Model [J]. Journal of Highway and Transportation Research and Development, 2022, 39(5): 112–121.

skin response signal (GSR) to fuse various physiological signals, and builds the driver's driving fatigue state database. According to the collected data and subjective evaluation, this study analyzes the changing rules of drivers' states, selects effective indicators for analysis and comparison, and explores the changing trend of each indicator and fatigue degree. The results show that the changing trend of HRV characteristics in photoplethysmographic signal (PPG) is consistent with the existing research, most of the time-domain and frequency-domain indicators change with the deepening of fatigue, and the complexity of nonlinear indicator C_0 decreases; The sample entropy (SampEn) index of galvanic skin response signal decreases gradually. According to the law and characteristics of state change, combined with subjective evaluation, this paper analyzes the driver's fatigue state and set the fatigue state level. In this paper, the driving state is set to be awake state, slight fatigue state, and severe fatigue state. Then, according to Pearson correlation coefficient (PCCs), collinearity analyses and Mann-Whitney U test are conducted to complete index optimization. Finally, this study constructs a fatigue evaluation Hidden Markov Model (HMM) for fatigue level classification and carries out fatigue driving detection. The test results show that the trained HMM fatigue detection model has an accuracy rate of 90%.

Key words: safety engineering; fatigue driving; physiological index; multiple feature fusion; Hidden Markov Model (HMM); fatigue classification

Research on fatigue driving detection based on multi-physiological signal fusion

GONG Shujuan¹, ZHAO Yongxiang², HUANG Deming³

(1 Department of Management, Quanzhou Vocational College of Economics and Business, Quanzhou 362000, Fujian, China; 2 School of Economics and Management, Fuzhou University, Fuzhou 350108, China; 3 State Grid Quanzhou Electric Power Supply Company, Quanzhou 362000, Fujian, China)

Abstract: To reduce traffic accidents and ensure road traffic safety, this paper proposes a more effective method to detect the driving state of drivers. In this study, 24 volunteers are recruited as experimental subjects. First, This paper designs and carries out driving experiments with the help of a simulated driving platform, and grades the fatigue state of the subjects through subjective evaluation. Furthermore, this study collects physiological data, uses pulse wave signal (PPG) and galvanic