

分类号:

密级:

U D C:

学号: 406130915124

南昌大学硕士研究生

学位论文

基于经验模态分解的多尺度熵在疲劳驾驶前额脑电 特征抽取方法上的研究

The Study of Feature Extraction Method by Multiscale Entropy
Based on Empirical Mode Decomposition in Fatigue Driving
Forehead Area EEG Signals

刘 超

培养单位(院、系): 信息工程学院

指导教师姓名、职称: 邱桃荣 教授

申请学位的学科门类: 工 学

学 科 专 业 名 称: 计算机科学与技术

论 文 答 辩 日 期: 2018年6月2日

答辩委员会主席: 甘登文

评阅人: 徐江峰

朱玉灿

2018年 月 日

摘 要

疲劳驾驶是现阶段导致交通事故发生的重要因素之一。本文研究分析驾驶员正常状态和疲劳状态下的不同前额脑电,提出了一种经验模态分解下自适应多尺度熵的脑电特征提取算法。所提出的算法是基于前额 2 个导联数据进行分析的,采集这 2 个导联的脑电数据不仅能有效地降低导联信号受毛发等因素的影响,而且基于前额导联设计出来的采集装置易于携带、实用性强。在这些数据基础上,针对脑电熵特征提取的尺度信息难于确定以及疲劳驾驶状态分类研究中存在分类准确率不理想问题。论文研究了在经验模态分解下如何选择自适应尺度重构脑电数据进行脑电分析,以便能提高分类准确率。论文主要的工作和创新点如下:

(1) 针对现有的脑电多尺度熵算法中存在尺度信息难于确定的问题。本文研究如何自适应的获取尺度来计算多尺度熵以提高疲劳驾驶检测的准确率,提出了一种自适应获取尺度因子(ASF)的方法。通过数据集的测试实验表明,使用 ASF 方法获得的尺度因子重构信号后计算得到的自适应多尺度熵特征对疲劳驾驶检测的准确率相对于单尺度下对疲劳驾驶的检测率有显著的提高。

(2) 考虑脑电信号具有非线性特征,而使用经验模态分解技术分解信号,研究如何选择信号分解的模态分量来计算尺度熵以更有效改进疲劳驾驶检测的准确率方法。引入单模态分量相关系数,选择与输入信号存在弱相关性的模态分量用于计算自适应多尺度熵特征进行分析。实验表明该方法得到的经验模态分解的自适应多尺度熵特征能够更有效提高疲劳驾驶检测的准确率。

本文分析传统的多尺度熵算法,提出了一种自适应尺度因子的方法,将获得的自适应尺度因子重构信号得到自适应多尺度熵特征,以及结合经验模态分解的方法得到基于经验模态分解的自适应多尺度熵特征。在七种分类器下,采用多次实验方法得到经验模态分解的自适应多尺度熵特征比自适应多尺度熵以及单尺度熵特征对疲劳驾驶检测的准确率都要高。文中所提出的方法可以为脑电疲劳驾驶检测提供一定的参考价值。

关键词: 疲劳驾驶; 前额脑电; 经验模态分解; 自适应; 多尺度熵

ABSTRACT

Fatigue driving is one of the important factors causing traffic accidents at this stage. An EEG feature extraction algorithm based on adaptive multi-scale entropy under empirical mode decomposition for analyzing the different forehead EEG signals of the driver's normal state and fatigue state in this studies. The proposed algorithm is based on the analysis of the forehead and two electrode data, which can not only effectively reduce the influence of signals from hair and other factors, but also the acquisition device designed based on the forehead electrode is applicable with great utilization value. Based on these data, it is difficult to determine the scale information for extracting the entropy feature and the problem of unsatisfactory classification accuracy in the study of fatigue driving state classification. In order to improve the classification accuracy, choosing adaptive scale to reconstruction signal data for EEG analysis under empirical mode decomposition. The main work and innovations of the paper are as follows:

(1) Aiming at the problem that existing scale information is difficult to determine in the existing EEG multiscale entropy algorithm. An adaptive acquisition scale factor (ASF) method is proposed, which obtain adaptive scales to calculate multi-scale entropy to improve the accuracy of fatigue driving detection in this studies. The test results of datasets show that the accuracy of the adaptive multiscale entropy feature calculated by using the scaling factor obtained by the ASF method to calculate the fatigue driving detection is significantly higher than the detection rate at the single scale.

(2) Considering that the EEG signal has nonlinear characteristics, to more effectively improve the accuracy of the fatigue driving inspection method to select the modal component of the signal decomposition by EMD technique, which is used to decompose the signal. Selecting modal components that have weak correlation with the input signal for calculation of adaptive multiscale entropy features introduced single-mode component correlation coefficients. Experiments show that the adaptive multiscale entropy feature of empirical mode decomposition obtained by this method can more effectively improve the accuracy of fatigue driving detection.

This paper analyzes the traditional multiscale entropy algorithm and proposes an adaptive scaling factor method. Get the self-adaptive scale factor to reconstruction signal for calculate the multi-scale entropy feature, and combined with the empirical mode decomposition method, an adaptive multiscale entropy feature based on empirical mode decomposition is obtained. Under the seven classifiers, the adaptive multi-scale entropy features of the empirical mode decomposition obtained by multiple experiments are higher than the adaptive multiscale entropy and the single scale entropy feature for the accuracy of fatigue driving detection. The method proposed in this paper can provide some reference value for the detection of EEG fatigue driving.

Key words: Fatigue driving; Forehead EEG; Empirical mode decomposition; Self-adaptive; Multiscale entropy

目 录

第 1 章 绪论	1
1.1 疲劳驾驶背景及意义	1
1.2 疲劳驾驶状态识别方法的研究现状	2
1.3 基于 EEG 脑电信号的疲劳驾驶识别方法研究现状	5
1.4 本文的主要研究内容	7
1.4 本文的组织结构	8
1.5 本章小结	8
第 2 章 脑电信号及相关理论简介	9
2.1 脑电信号介绍	9
2.1.1 脑电的产生	9
2.1.2 脑电的采集电极放置位置	10
2.2 经验模态分解的相关简介	11
2.2.1 经验模态分解概述	11
2.2.2 经验模态分解算法	11
2.3 熵特征概述	12
2.3.1 排列熵	13
2.3.2 样本熵	13
2.3.3 模糊熵	14
2.4 分类器描述	15
2.5 本章小结	16
第 3 章 基于经验模态分解的自适应多尺度熵模型构建及算法描述	17
3.1 模型构建	17
3.2 模型的中的相关参数说明	18
3.3 自适应尺度因子概念及算法描述	19
3.3.1 尺度概念	19
3.3.3 自适应尺度因子算法(ASF)描述	20

3.3.4 算法时间复杂度分析	22
3.4 单模态分量相关(SIMFR)系数	22
3.4.1 单模态分量相关系数定义	23
3.4.2 模态选择指标	23
3.5 两种自适应多尺度排列熵算法描述	23
3.5.1 自适应多尺度排列熵特征算法	23
3.5.2 基于经验模态分解的自适应多尺度排列熵特征算法	24
3.5.3 算法时间复杂度分析	26
3.6 两种自适应多尺度样本熵算法描述	26
3.6.1 自适应多尺度样本熵特征算法	26
3.6.2 基于经验模态分解的自适应多尺度样本熵特征算法	27
3.6.3 算法时间复杂度分析	29
3.7 基于经验模态分解的自适应多尺度模糊熵算法描述	29
3.7.1 多尺度模糊熵特征算法	29
3.7.2 基于经验模态分解的自适应多尺度模糊熵特征算法	30
3.7.3 算法时间复杂度分析	32
3.8 本章小结	32
第 4 章 基于经验模态分解的自适应多尺度熵算法测试	33
4.1 实验预处理及性能评价	33
4.1.1 实验软硬件平台	33
4.1.2 数据采集	33
4.1.3 数据预处理	34
4.1.4 实验个体选择	35
4.1.5 性能评价矩阵	37
4.2 自适应尺度因子及相关模态分量的选择	37
4.2.1 尺度因子的确定	37
4.2.2 相关模态分量的选择	40
4.3 熵特征算法在检测疲劳驾驶中测试	42
4.3.1 多尺度熵特征对疲劳驾驶的检测	42

目 录

4.3.2 基于经验模态分解的多尺度熵特征对疲劳驾驶的检测	43
4.3.3 基于经验模态分解的多尺度熵特征在多种分类器下的测试	44
4.4 本章小结	47
第 5 章 总结与展望	49
致谢	51
参考文献	52
攻读学位期间的研究成果	57

第 1 章 绪论

1.1 疲劳驾驶背景及意义

世界卫生组织 2015 年公布的交通事故调查报告显示全球每年有将近 125 万人在交通事故中伤亡，其中在我国发生的交通事故的伤亡人数多达 261367 人占全世界伤亡总人数的 1/5，同时世界卫生组织也预测到 2020 年道路交通伤害造成的疾病和伤害负担将由原来的第九位上升到第三位，如果不采取措施预计到 2030 年道路交通事故将成为全球的第七大死因^[1]。2016 年我国发生的交通事故达 864 万起，其中有 6.3 万人死亡，23 万人受伤^[2]。交通事故的如此频发，一方面是因为国民收入水平提高国民人均持有的车辆增加，另一方面也是因为人们各种酒驾，疲劳驾驶，不规范驾驶等现象增多导致了这么高的伤亡率。根据公安部交通运输部的数据统计显示 2016 年我国的机动车保有量达 2.9 亿辆，其中汽车的保有量达 1.94 亿辆，驾驶人数量达 3.6 亿人^[3]。在不断提升拥有车辆基础上，道路交通事故已成为国民的重大安全隐患，不采取有效措施将对人民的生命及财产安全构成巨大的威胁。

疲劳驾驶是交通事故发生的高频因素之一。国内学者张丽霞等人^[4]分析得出人的因素是导致交通事故最大的因素并通过定量分析发现酒后驾驶、疲劳驾驶、超速行驶、逆向行驶为最主要的四个导致交通事故的人为因素。据公安部交通管理科学研究所统计，我国每年的道路交通伤亡事故人数超过 20 万^[5]。国际上对疲劳驾驶也有许多调查，如美国每年因瞌睡导致近 10 万起的交通事故，其中造成人身伤害的交通事故达 71%，直接造成人死亡有 1500 起。法国警察署也统计该国有近 20.6% 的交通事故是由瞌睡导致的^[6]。日本每年因疲劳驾驶产生的交通事故约占 1.0% 到 1.5%^[7]。在汽车的驾驶过程中需要驾驶员高度集中注意力，这种情况下人的大脑容易出现疲倦等生理状态，在面对周围变化着的环境时容易出现反映迟钝、判断力、注意力等下降的情况，这样无疑会增加驾驶员驾驶汽车的风险，导致一些不必要的交通事故发生。因此，能够及时判别或检测出驾驶员驾驶汽车过程中是否处于疲劳状态并做出及时的预警提示是个非常有意义且具有广阔研究前景和巨大的应用价值的课题。

本课题得到国家自然科学基金项目[No.61762045，61662045]的资助。

1.2 疲劳驾驶状态识别方法的研究现状

疲劳驾驶一直是各国专家学者研究的热点问题。很多专家学者大多通过以下四方面对疲劳驾驶检测进行研究，一是设计疲乏表用于评定驾驶员的疲劳程度；二是依靠人的生理特性来检测疲劳驾驶，因为人处于疲劳状态时人的生理特性等方面的状态会有别于人的正常状态；三是人处于疲劳时人会出现一些像打哈欠、眨眼频率变低等现象，因而捕捉人的脸部表情动作，借助机器视觉的方法分析人在疲劳状态下的视觉特征；四是根据车辆它本身的运行轨迹，如疲劳状态下人的脚控制刹车的力度变小，固定姿势的时间变长等而导致车辆本身偏离正常的行驶轨迹。下面就这四个方面简要阐述：

1.基于疲乏表的主观评定法在疲劳驾驶上的研究现状

目前对于嗜睡和大脑疲劳采用了不同的疲乏表，其中有 Piper 疲乏表^[8]、Stanford 疲乏表^[9]和 Epworth 嗜睡表^[10]，通过问卷调查的形式发放给驾驶员；驾驶员在驾驶一定时间后对表中的各个选项进行状态判断，由其他人员对驾驶员的疲乏表进行打分进而判断是否处于疲劳状态。对于这种主观的评定法存在两个方法的缺陷。首先，这种方法它不适用于实际的驾驶情况因为对于驾驶员而言这具有一定的危险性，所以一般在模拟驾驶中采用这种方法。其次，由于个体主观的差异性，驾驶员自己对一些疲劳产生的现象判断并不一致，导致打出的分数波动比较大，因而只能作为是否疲劳的大概参考。

2.基于人的生理特性在疲劳驾驶上的研究现状

人生理特性如脑电、眼电、心电等最早被用于医学研究^[11,12]，目前也有专门学者针对这些生理特性，将它作为一项指标运用于驾驶员在驾驶汽车中是否出现疲劳的检测。有以下几种指标：

(1) 基于脑电(EEG)检测

基于脑电的疲劳检测在检测前需要采集脑电数据。脑电数据一般通过脑电采集帽进行，通常在国际上标准的脑电采集帽有 32、64、128 等不同数目的电极选择，最终采集得到的脑电数据也是 32、64、128 等多个维度的数据。脑电数据采集后就可采用不同的处理方法进行数据处理和分析。Hu 等人^[13]通过计算 30 个导联的数据模糊熵、近似熵、样本熵、谱熵特征，并组合这四种熵特征作为集成分类器的输入，最后的疲劳驾驶检测的准确率达 96.6%。Wang 等人^[14]提

出了一种滑动窗口下小波熵耦合神经网络的方法，并通过分析结果的输出分布情况，得到驾驶的危险点与实际事故点具有高度一致性的结论。Gharagozlou 等人^[15]分析了驾驶员在执行模拟驾驶任务时，发现一些睡眠不足的驾驶员的脑电 α 频率段的变化，得出 α 波段可以作为驾驶员疲劳驾驶检测的一个指标。脑电信号它本身的特点就是时序非平稳的特性，因此对于它本身而言就有采用时域分析法^[16]、频域分析法^[17-19]、以及时频结合的分析方法^[20]。

(2) 基于眼电(EOG)检测

眼电也是一种常采用的疲劳驾驶检测技术，一般和脑电一起作为驾驶员的原始输入数据进行分析^[19,21]。A Němcová 等人^[22]通过抽取眨眼、慢速眼动(SEM)、快速眼动(REM)等眼电特征用于疲劳的检测。吕钊等人^[23]对 15 位测试者通过眼电采集装置采集眼电，并使用独立分量分析的方法进行空域滤波后提取眼电特征，同时结合 SVM 支持向量机对测试者进行疲劳分类测试，实验结果显示该算法具有良好的分类性能。

(3) 基于心电(ECG)检测

心电由于其相比脑电和眼电它的电信号强度更强因而在实际采集过程中它所受其它生物电信号干扰更小更有利于对实验的分析。Wang 等人^[24]通过间接接触心电图测量系统发现心率可变性能够用于评估疲劳的水平。Chen 等人^[25]不同于其他研究者使用心电图的 R 波和 R 波间隔(RRI)作为分析的生理数据而是使用 R 波幅(RWA)作为数据源，发现在清醒、睡眠这之间 RWA 变化显著因而可以用于确定瞌睡时的初始阈值。

3. 基于机器视觉特征在疲劳驾驶上的研究现状

视觉特征主要是通过图像传感器捕获驾驶员的脸部位置变化、眼睛眨眼频率及眨眼时间、嘴巴闭合状态等变化从而判断驾驶员是否处于疲劳或非疲劳状态。

(1) 基于面部特征检测

正常状况下采用整体的面部特征比单独的考虑眼睛或者嘴部的变化更具优势。周云鹏等人^[26]提出了一种面部多特征融合的算法对眼睛和嘴部信息使用 Gabor 滤波及梯度增强信息，然后分别用 LBP 抽取眼部特征，根据嘴部的面积

等信息计算嘴部的闭合状态以及获得眼部的位置等特征，实验显示该算法具有很好的识别率。Karchani M 等人^[27]捕获动态的面部表情提出了一种检测疲劳的复合模型能够有效的识别疲劳状态。

(2) 基于眼部特征检测

人在疲劳状态下眼睛会感觉酸痛沉重、眼睑下垂、眼睛张合度变小等，可以通过捕捉眼部的位置及眼睛的状态等特征分析人的疲劳状态。PERCLOS 法被广泛的运用于眼部检测，它通过计算眼部的闭合程度的时间占总时间的百分比作为有效的参数，Acioğlu A 等人^[28]通过红外装置照射眼睛检测眼睛的位置并实时计算分析眼睛闭合程度的时间计算 PERCLOS，使用眼睛的状态分析驾驶员的困倦程度。赵晓琳等人^[29]先对图像预处理分离出人脸和眼睛，并计算睫毛和眉毛之间的距离再计算眼部区域内黑色像素点的个数作为两个输入参数判断眼睛是否处于闭合状态，把连续 5 帧的图像眼睛处于闭合状态的发出疲劳预警。

(3) 基于嘴部特征检测

嘴部状态的变化同样也能反映出人的疲劳状态的变化，尤其是人在打哈欠的时候嘴部的状态表现出来的是不一样的。付锐等人^[30]通过建立灰度能量角点的嘴唇动态匹配模型能够检测出三种嘴部状态分别是“说话”、“闭嘴”、“打哈欠”，并能够计算出疲劳预警检测的精度为 92.9%。Ibrahim 等人^[31]充分考虑到人在打哈欠的时候脸部会出现皱纹或者遮挡住口部，使得一些嘴部状态不易被检测出来，因而引入自适应的颜色区域并计算 LBP 纹理特征判断嘴部的状态是否有遮挡，另外设定阈值判断是否处于疲劳打哈欠状态。

4. 基于车辆的运行轨迹在疲劳驾驶上的研究现状

人疲劳状态下精神是涣散的，通常这种情况下驾驶员不能很好的控制车行驶的轨迹，要么车长时间压道行驶而不能及时修正，要么方向盘转动幅度过大而不能及时摆正，另外脚在踩油门和刹车是力度不均匀，深一脚浅一脚的情况时有发生。Eskandarian 等人^[32]通过计算驾驶员在打方向盘时的角度方差和平方差来分析驾驶员的疲劳状态。孙香梅^[33]充分利用三轴加速传感器、方向盘转向传感器及计算机系统构建了一个基于车辆行驶轨迹的疲劳驾驶检测模型，该模型最终通过使用模糊数学理论识别驾驶员的疲劳状态，因而证明了通过分析车辆轨迹是能够判断驾驶员的疲劳状况。

1.3 基于 EEG 脑电信号的疲劳驾驶识别方法研究现状

脑电是一种非静态、非线性的时序信号被广泛的运用于医学领域，已在癫痫的治疗、抑郁症的识别等病症上取得很好的效果。同样也有学者针对驾驶员疲劳驾驶容易引发交通事故这一问题，分析对比驾驶员在正常状态和疲劳驾驶状态下不同的脑电数据，能够有效的识别驾驶员疲劳驾驶，做出及时的预警指示。他们采用了多种不同的方法分析脑电信号，如基于时域的波形特征分析、互相关性分析等方法、基于频域的无参功能谱和有参功能谱的方法、基于时频域结合的小波变换和快速傅里叶变换等方法以及非线性的动力学中的样本熵、模糊熵等特征提取的方法。在以上方法中，Zhao 等^[34]人提出了一种脑电的部分互信息相关性特征选择算法(PMIS)。该方法是基于统计学的特征选择算法，能够消除一些不重要的特征，而选择有效特征计算，最终能够提高分类准确率，并得到 Channel 1 相比于其他的 Channel 的特征更为重要。Chai 等人^[35]通过独立主成分分析法在 32 个导联数据中选择了其中的 16 个导联数进行处理，最后通过提取功率谱密度 PSD 的方法得到识别率在 75.5%。这种基于频域的方法得到准确率并不高，后来 Ozmen 等人^[36]提出了一种改进的方法，通过分析功率谱密度(PSD)的频率分布情况来提高识别率，最终得到平均的二分类准确率为 83.06%、多分类的准确率为 91.85%。Dkhi1 等人^[37]根据快速傅里叶变换的方法计算出脑电信号的频带功率，能够用于检测驾驶员大脑的不同疲劳程度。Wali 等人^[38]采用离散小波变换(DWT)的方法分析驾驶员脑电信号，得到疲劳驾驶检测的准确率为 79%。由于离散小波变换的过程是将输入信号通过小波基函数的缩放和移位形成的分解而得到小波系数集，而小波基函数的选择会影响到实验结果，并且在 DWT 分解的过程中需要获得足够多的小波系数^[39]。在这种情况下小波包分解(WPD)^[40]拓宽了 DWT 的处理能力，能够对频带多层次、多分辨率分析是一种更加精细的处理方法。后来 Alickovic E 等人^[41]又将小波包分解方法和多尺度主成分分析法(MSPCA)结合，用于对癫痫发作的检测和预测，最终能够达到的预测率为 99.77%。熵是一个系统内部复杂性的度量，同样可以运用于驾驶员的脑电检测领域。其中有排列熵，样本熵、模糊熵等脑电特征提取的方法。Wan 等人^[42]通过抽取驾驶员在愤怒状态下脑电信号(EEG)和血容量脉搏信号(BVP)的样本熵特征，得到 EEG 样本熵小于 0.5817 且 BVP 样本熵大于 0.6037 时，驾驶员可能处于愤怒状态的识别准确率为 80.41%。Mu 等人^[43]采用模糊熵的特征提取算法，通过分析人的前额导联 FP1 和 FP2 的数据发现 FP1 与

FP2作为联合导联在疲劳驾驶分类准确率上达85%，高于单个的导联PF1的79%和导联FP2的68%。这种方法只用到了两个电极数据在一定程度上减少了计算所用的时间，但是由于使用的是单一的模糊熵特征，导致疲劳驾驶检测的准确率不高，模型的抗噪能力不强，后来Hu^[44]等人通过在原始信号中加入高斯白噪声、Spike噪声以及模拟的肌电(EMG)噪声信号，提取信号的近似熵、样本熵、谱熵、模糊熵等特征，采用决策树、支持向量机及集成学习的分类算法分析，发现模糊熵和集成分类算法组合的方式对噪声的敏感度低、鲁棒性强。然而这种方法只是将噪声数据和原始信号数据进行简单的线性叠加，没有考虑到随机噪声数据、局部噪声数据的分析，因而也存在一定的局限性。同时从算法的效率上考虑，由于提取了全部导联数据的特征，一方面需要计算特征的时间偏高，不利于的实际的应用，另一方面并不是所有的电极的信息都重要，没有对电极数据进行选择性的筛选。Min^[45]等人通过计算每个电极对疲劳驾驶检测的准确率，分析得到了每个电极对于疲劳驾驶检测的价值权重。并得到最优的十个电极以及它们分布的五个脑区域，然后针对脑电局部区域的联合电极进行疲劳驾驶的检测，得到电极TP7、CP3、T5、P3构成的区域疲劳驾驶检测的效果最好，最高的疲劳驾驶检测的准确率达98.3%。

前面几篇关于疲劳驾驶检测的脑电信号熵特征提取的文献中，有用到排列熵、样本熵、模糊熵等熵特征。这些熵算法各有其优缺点，其中排列熵相比于其它几种熵而言其计算速度快，适合实时处理和分析信号，但同时容易受嵌入维数的影响使得其算法的稳定性不高。样本熵是由近似熵发展而来的，它解决了近似熵对样本长度的敏感性问题，使得它可以不受信号数据长度的影响具有抗噪、抗干扰能力强的特点。模糊熵在求相似容限值时采用了一种模糊隶属度函数替代了样本熵中硬阈值的判别法，使得它能够有效提高准确率。但是排列熵、样本熵、近似熵等都是单时间尺度下计算得到的，不能反映出信号本身在多时间尺度下的自相似性和复杂度。同时又由于多尺度熵中的尺度信息难于确定的问题。因而本文为了提高脑电疲劳驾驶检测的准确率构建脑电信号的自适应多尺度时间序列。又由于脑电信号受限于人的大脑活动，其表现为脑电信号微弱，在采集脑电的时候容易受到噪声的干扰，因此本文结合经验模态分解的方法对脑电信号进行预处理。另外前面也有文献分析计算全部脑电极信号需要花费的时间偏长，然而并不是所有的脑电信号都能起作用^[45]，因此本文针对特定脑区域即前额脑区域进行分析。虽然已有学者针对该区域进行过分析^[43]，但

其采用传统的模糊熵特征对疲劳驾驶检测，得到的检测准确率并不高。因此本文拟同样分析前额区域电极 Fp1、Fp2，一方面该区域受毛发等因素的影响小，可以从采集源减少数据采集的噪声，另一方面针对该区域的分析，方便以后设计前额脑电采集装置，提高应用的实用性。

1.4 本文的主要研究内容

本文研究内容主要包括：

针对基于 EEG 进行疲劳驾驶检查方法中采用的所有电极得到的 EEG 数据存在以下问题：一是 EEG 数据采集不方便、二是所采集的 EEG 数据存在较多噪音；三是单尺度熵算法准确率不高、多尺度熵算法难于确定尺度信息；四是实际应用存在困难。

在分析目前研究领域脑电数据的特征，发现传统的基于信号的熵的特征方法用于疲劳驾驶的检测存在一些缺陷。本文同样分析疲劳驾驶脑电 EEG 信号，不同的是本文并没有同其它论文一样选择所有电极数据计算，而选择人前额两个电极数据分析。主要是因为人的前额脑电采集方便，没有头发等因素影响采集的数据；另一个原因是，若分析所有电极数据的特征势必会增加计算时间。此外，基于传统的脑电信号的熵特征如样本熵(SE)、模糊熵(FE)、排列熵(PE)等这些特征都只是在单一时间尺度下分析数据。同时对于多尺度熵(MPE、MSE、MFE)而言，又不能很好的确定信号的时间尺度信息。因此本文在原有的熵的特征基础上增加多尺度信息提出了自适应多尺度样本熵(AMSE)、自适应多尺度模糊熵(AMFE)、自适应多尺度排列熵(AMPE)特征算法。脑电本身是一种非静态、非线性信号，存在很多不确定的噪声数据。为了提高疲劳驾驶的识别率以及结合信号本身的非线性特点引入自适应性强的经验模态分解技术，用于信号的分解而引入单模态分量相关系数选择固有模态函数分量。再结合自适应尺度因子算法提出了经验模态分解的自适应多尺度排列熵(IMF_AMPE)特征算法、经验模态分解的自适应多尺度样本熵(IMF_AMSE)特征算法、经验模态分解的自适应多尺度模糊熵(IMF_AMFE)特征算法。最后，再通过实验对比分析单尺度熵、自适应多尺度熵以及经验模态分解下的自适应多尺度熵特征在疲劳驾驶中的测试。

1.5 本文的组织结构

本文总共分成 5 章内容：

第 1 章介绍了疲劳驾驶目前研究的背景、现状及意义以及介绍本论文主要的研究内容。

第 2 章阐述了本论文所使用方法的相关理论，如经验模态分解技术、样本熵、模糊熵、排列熵等概念以及实验中用到的分类器。

第 3 章主要介绍了基于经验模态分解的自适应多尺度熵模型的构建及所提出算法的相关描述。

第 4 章主要对基于经验模态分解的自适应多尺度熵算法在疲劳驾驶中的检测及实验测试。

第 5 章为本次论文的总结与展望

1.6 本章小结

本章首先介绍疲劳驾驶研究的背景及意义。其次在四个方面对疲劳驾驶状态识别方法的研究现状进行介绍，分别是主观评定法在疲劳驾驶中的研究现状、生物电特征在疲劳驾驶中的研究现状、基于视觉特征在疲劳驾驶中的研究现状以及车辆本身的运行轨迹在疲劳驾驶中的研究现状。然后，特定性的对基于 EEG 脑电信号的疲劳驾驶识别方法的研究现状介绍。最后给出了本文的主要研究内容及本文简要的组织结构。

第2章 脑电信号及相关理论简介

2.1 脑电信号介绍

2.1.1 脑电的产生

大脑的一个主要组成部分是大脑皮质，负责人脑高级的认知和情绪的变化功能，主要分为左大脑和右大脑，而左大脑和右大脑又分别包括了额叶脑、顶叶脑、枕叶脑、颞叶脑。脑电波(electroencephalogram, EEG)简称脑电，是一种使用电生理指标记录大脑活动的方法，是大脑在活动时，借助大量神经元同步发生的突触电位活动后形成的。它记录大脑活动时的电波变化，是脑神经细胞的电生理活动在大脑皮层或头皮表面的总体反映。一般脑电也可以分成自发脑电和诱发脑电两种：

(1) 自发脑电：自发脑电(spontaneous potential, SP), 是指没有特定外界刺激时大脑神经细胞群自发电活动在头皮上产生的电位变化，这种大脑皮层有持续性、节律性的电位变化称为自发脑电。其包含丰富的生理及病理信息，因而成为脑科、神经科学的重要研究对象和临床脑神经与精神疾病诊断的重要检测手段^[46]。对不同部位的脑叶区，脑电形成的频率和振幅也是不同的。

(2) 诱发脑电：诱发脑电(evoked potential, EP)是指人为的对外围感觉神经、感觉通路与感觉系统有关的任何结构进行施加适当的刺激时所引起的脑电位变化^[47]。其中又可以分为特异性诱发和非特异性诱发，特异性诱发是指在给予一定的脑电位刺激后经过一定的潜伏期，在脑的特定区域出现的电位反应，而非特异性脑电诱发指给予不同的刺激时产生相同的反应，这是一种普遍的和暂时的情况。

在现代脑电图中将脑电按照不同的频率划分四个频率段^[48]： β 波(14~30Hz)、 α 波(8~13Hz)、 θ 波(4~7Hz)和 δ 波(1~3Hz)。不同波段表现对应于不同的大脑状态。检测到的 β 段一般是人处于精神紧张和情绪亢奋状态； α 波段一般是正常人脑电波的节律，在没有外界的刺激处于清醒的状态时该节律波最为明显； θ 波一般在人的意志消沉或者是受到抑郁精神不振时表现较为显著； δ 波一般是人在极度疲劳或者是昏睡状态下容易产生该频段脑波。四种脑波的波形图如图 2.1 所示：




图 2.1 人脑四种频率波段

2.1.2 脑电的采集电极放置位置

脑电采集用到的电极帽一般是按照标准的 10-20 国际标准系统电极位置放置^[49]。它主要按照测试者脑颅的比例大小放置电极，所有电极的标准位置应当覆盖头部所有的部位，其位置如图 2.2 所示，

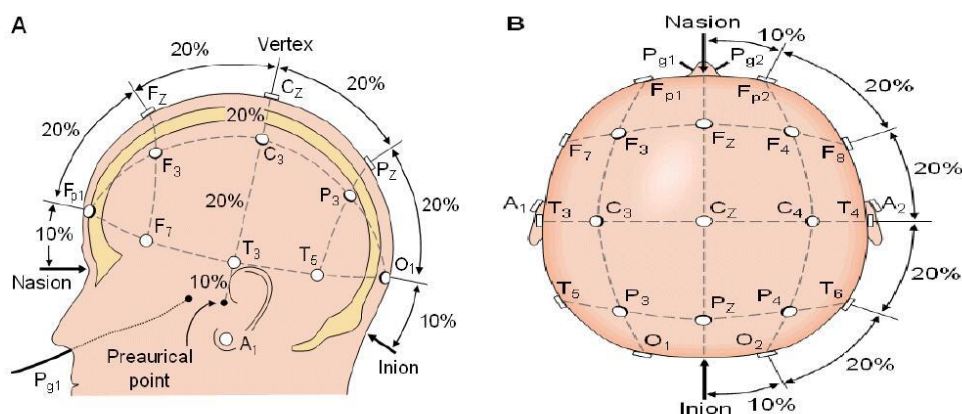


图 2.2 10-20 国际标准系统电极位置

其中包括前后和左右两条线^[50]，前后线是从鼻根至枕外粗隆取一连线。在此线上，由前至后标出 5 个点，依次命名为：额极中点(Fpz)、额中点(Fz)、中央点(Cz)、顶点(Pz)、枕点(Oz)，左右线是从左耳前点(耳屏前颧弓根凹陷处)通过中央点至右耳前点取一连线，在此连线的左右两侧对称标出左颞中(T3)、右颞中(T4)、左中央(C3)、右中央(C4)。EEG 电极一般左半脑为奇数，右半脑为偶数，A1 和 A2 分别表示左右两个耳电极，所有电极用阿拉伯数字表示如表 2.1 所示。脑电的采集本质是记录脑电两电极的电位信号差，即差分信号。

表 2.1 10-20 电极安放命名

大脑部位	英文名	电极代号
前额	Prefrontal lobe	Fp1、Fp2
侧额	Inferior frontal lobe	F7、F8
额区	Frontal lobe	F3、F4、Fz
中央	Central lobe	C3、C4、Cz
颞区	Temporal lobe	T3、T4
后颞	Posterior temporal lobe	T5、T6
顶区	Parietal lobe	P3、P4、Pz
枕区	Occipital lobe	O1、O2
耳	Auricular	A1、A2

2.2 经验模态分解的相关简介

2.2.1 经验模态分解概述

经验模态分解(empirical mode decomposition, EMD)理论最早是由 Huang 等人提出来的，他假设任何复杂的信号都可以分解为有限数目且具有一定物理意义的固有模态函数^[51]。目前被广泛的应用于信号处理领域，它是一种自适应性强的处理技术，基本思想是将数据信号分解成若干个表征该信号分量的固有模函数(IMFs)，而这些固有模函数的提出也是为了能够获得信号的瞬时频率。每个固有模函数必须要满足以下两个条件：

- (1) 在整个信号分解后得到的数据区间每个固有模分量必须满足极值点的个数和过零点的个数相等或者它们之间相差 1。
- (2) 在任何一点处，由极大值连线构成的上包络线同极小值连线构成的下包络线它们的均值必须为 0。

2.2.2 经验模态分解算法

EMD 的分解的过程即是一个筛选的过程，根据信号的特点，将信号分解成由高到低不同频率的一系列的固有模态函数，该方法直接从信号源获取基函数，因此具有自适应性^[52]。可以描述为以下几步：

(1) 抽取信号 $x(t)$ 中的极大值和极小值，然后分别采用三次样条插值把极大值和极小值用插值曲线连接起来，使得曲线包含了所有的信号数据，从而得到 $x(t)$ 的上包络线 $\varepsilon_{max}(t)$ 和下包络线 $\varepsilon_{min}(t)$ 。

(2) 计算上包络线 $\varepsilon_{max}(t)$ 和下包络线 $\varepsilon_{min}(t)$ 的平均值 $m(t)$:

$$m(t) = \frac{\varepsilon_{max}(t) + \varepsilon_{min}(t)}{2} \quad (2.1)$$

(3) 把均值 $m(t)$ 从信号 $x(t)$ 中减掉得:

$$D(t) = x(t) - m(t) \quad (2.2)$$

(4) 检查 $D(t)$ 是否满足构成 IMF 的两个条件。

(5) 重复(1)到(3)的步骤直到满足 IMF 的两个条件。

(6) 最终信号 $x(t)$ 可以表示为多个 IMF 信号分量和剩余量 $R(t)$ 的和，如下:

$$x(t) = \sum_{i=1}^K IMF_i(t) + R(t) \quad (2.3)$$

公式(2.3)中的 K 为抽取出的固有模函数的数量， $R(t)$ 表示最终不满足 IMF 条件的常数或者是单调函数。至此信号的分解过程结束，得到的 K 个标号从小到大的固有模函数分量分别表示原信号的时间尺度从细到粗的特征信号，剩余量代表信号的发展趋势。以上过程是一种信号的自适应的处理方式，不同于小波变换对信号的处理而需要选择基函数。

2.3 熵特征概述

熵最早是热力学中的一个概念。反映一个系统它所处的宏观态所具有的微观态数目或热力学几率，与热力学几率的对数成正比的混乱度，被用于表述一个系统复杂度的度量。之后由香农引入信息科学中用来度量信息量大小的一种方式，具体意义表示为平均信息量的大小称之为信息熵^[53,54]。事件 P 的信息熵可以表示为:

$$En(P) = -\sum_{i \in X} P_i \log(P_i) \quad (2.4)$$

之后由很多学者针对不同的领域问题提出了不同的熵的概念，其本质都来源于香农熵代表新信息产生的平均概率。其中在信号领域内针对信号的特征抽取方式有学者提出了以下的熵特征如：排列熵、近似熵、样本熵、模糊熵等，这些熵特征具体表示为新信号产生的平均概率大小。以下对其中用到的排列熵，样本熵，模糊熵作详细的理论介绍。

2.3.1 排列熵

排列熵(permutation entropy, PE)^[55]一个基于长时间序列的相邻数据对比的复杂度参数，是一种高效的非线性时序分析方法。它的计算速度快、鲁棒性好、对非线性变换具有不变性的优点，使其能够在医学、生物、机械、图像处理等领域内被广泛的运用，并适用于实时信号计算以及检测，以下是对排列熵的算法描述：

(1) 设有 N 个点采样时间序列 $\{X(i), i = 1, 2, 3, \dots, n\}$

(2) 相空间重构后得相空间重构矩阵

$$\begin{bmatrix} x(1) & x(1+\tau) & \dots & x(1+(m-1)\tau) \\ \vdots & \vdots & \ddots & \vdots \\ x(j) & x(j+\tau) & \dots & x(j+(m-1)\tau) \\ \vdots & \vdots & \ddots & \vdots \\ x(K) & x(K+\tau) & \dots & x(K+(m-1)\tau) \end{bmatrix} \quad (2.5)$$

($j = 1, 2, \dots, K$), 其中 m 为嵌入维数, τ 为延迟时间。

(3) 将 $x(i)$ 重构矩阵中的第 j 个分量 $x(j), x(j+\tau), \dots, x(j+(m-1)\tau)$ 按从小到大排列 j_1, j_2, \dots, j_m 为 m 个元素所在列的索引。 $x[i+(j_1-1)\tau] \leq x[i+(j_2-1)\tau] \leq \dots \leq x[i+(j_m-1)\tau]$

(4) 对于任意一个时间序列 $x(i)$ 重构所得的矩阵中每一行都可以得到一组符号序列 $S(l) = (j_1, j_2, \dots, j_m), l = 1, 2, \dots, k$ 且 $k < m!$

(5) m 维相空间映射不同的符号序列 j_1, j_2, \dots, j_m 总共有 $m!$, 符号序列 $S(l)$ 是其中的一种排列。

(6) 计算每一种符号出现的概率 p_1, p_2, \dots, p_k , 则排列熵定义为:

$$H_p(m) = -\sum_{j=1}^K p_j \ln(p_j) \quad (2.6)$$

当 $p_j = \frac{1}{m!}$ 时, $H_p(m)$ 达到了最大值 $\ln(m!)$ 。为了方便, 通常将该排列熵进行归一化处理:

$$0 \leq H_p = \frac{H_p}{\ln(m!)} \leq 1 \quad (2.7)$$

2.3.2 样本熵

样本熵(sample entropy, SE)^[56]最早是由 Richman 等人提出的一种时间序列复杂度的测度方法, 同样也是一种非线性信号分析方法。通过分析信号的复杂度来表征信号的非线性特征, 其中样本熵值越低, 信号自我相似性越高, 样本熵值越高, 信号自我相似性越低, 信号越复杂。样本熵不但具备抗噪能力,

而且能避免计算过程中因自身数据量比较而导致的统计量不一致的问题^[57]。具体的算法描述如下：

(1) 设有 N 个点采样时间序列 $\{t(i), i = 1, 2, 3, \dots, n\}$

(2) 构造一组 m 维的向量：

$$T_i^m = [t(i), t(i+1), \dots, t(i+m-1)]; 1 \leq i \leq N-m+1 \quad (2.8)$$

其中 m 为嵌入维数。

(3) 定义 d_{ij} 为任意两个 m 维向量之间的距离：

$$d_{ij} = \max\{|t(i+k) - t(j+k)|\} \quad (2.9)$$

其中 $i, j = 1 \sim N-m+1, i \neq j, k \in (0, m-1)$

(4) 给定 r 值，然后对每个 i 统计 d_{ij} 中小于 $r * SD$ (SD 为序列的标准差) 的数目 B_i ，并计算与距离的总数的比值：

$$B_i^m(r) = \frac{1}{L-m} B_i \quad (2.10)$$

(5) 定义 $B^m(r)$ 的平均值为：

$$B^m(r) = \frac{1}{L-m+1} \sum_{i=1}^{L-m+1} B_i^m(r) \quad (2.11)$$

(6) 设 $m = m+1$ ，重复步骤(2)到(5)得 B_i^{m+1} 和 $B^{m+1}(r)$ ：

$$B^{m+1}(r) = \frac{1}{L-m+1} \sum_{i=1}^{L-m+1} B_i^{m+1}(r) \quad (2.12)$$

(7) 样本熵可以被定义为如下：

$$H_s(m, r) = \log(B^m(r) - B^{m+1}(r)) \quad (2.13)$$

2.3.3 模糊熵

样本熵作为一种信号复杂度的计算指标，存在一定的缺陷。如采用硬阈值的方式设定相似容限值，这种方式使得选择阈值附近的值容易导致结果的突变，造成不同的判断结果。针对这一点，Chen 等人^[58]提出了模糊熵(fuzzy entropy, FE)的方法，将设置相似容限的方法改为软阈值法即用模糊隶属度函数替代硬阈值的判断标准。具体的算法描述如下：

(1) N 点采样序列为 $\{u_i: 1 \leq i \leq N\}$

(2) 按序列顺序重构生成一组 m 维矢量

$$X_i^m = \{u(i), u(i+1), \dots, u(i+m-1)\} - u_0 \quad (2.14)$$

$$u_0 = \frac{1}{m} \sum_{j=0}^{m-1} u(i+j) \quad (2.15)$$

(3) 定义矢量 X_i^m 和 X_j^m 间的距离 d_{ij}^m ：

$$d_{ij}^m = d[X_i^m, X_j^m] = \max\{|u(i+k) - u_0(i) - (u(j+k) - u_0(j))|\} \quad (2.16)$$

(4) 通过模糊度定义相似度：

$$D_{ij}^m = \exp(-\frac{(d_{ij}^m)^n}{r}) \quad (2.17)$$

(n,r分别代表指数函数的边界梯度和宽度)

(5) 定义函数:

$$O_{(n,r)}^m = \frac{1}{N-m} \sum_{i=1}^{N-m} \{ \frac{1}{N-m-1} \sum_{j=1, j \neq i}^{N-m} D_{ij}^m \} \quad (2.18)$$

(6) 定义模糊熵:

$$H_f(n, r) = \log(O_{(n,r)}^n - O_{(n,r)}^{n+1}) \quad (2.19)$$

2.4 分类器描述

在有监督的数据挖掘中，常常需要对不同类别的数据进行分类操作，因此选择一个合适的分类器显得尤为重要。因为脑电数据本身特点是非静态，非线性的，对于不同的分类器得到的结果差异比较大，本文采用了 7 种分类器分别是 RF,KNN,SVM,NB,DC,DT,ANN。以下对这几种分类器做简单的介绍。

(1) 随机森林(random forest, RF)^[59,60]，随机森林(RF)算法是由 Breiman^[17]提出的一种集成学习算法，它是利用随机重采用技术 bootstrap 和节点随机分裂技术构建多棵决策树，通过投票得到最优的分类结果。该算法具有优秀的分类能力，对于缺失数据和噪声数据具有强鲁棒性并且具有较快的学习速度。在本文对脑电的分类中树的最大深度设置为 10，决策树的数量也设置为 10。

(2) K 近邻算法(k-nearest neighbor algorithm, KNN)^[61]，K 近邻算法是一种简单的基于距离的有监督的分类算法^[19]。对于给定的测试样本，找到训练样本中距离该测试样本最近的 K 个样本，统计 K 个样本中出现次数最多的类别作为测试样本的类别。对于 K 的选取直接影响测试的结果，K 值得一般都选择奇数，本文选择 $K = 5$ 。

(3) 支持向量机(support vector machines, SVM)^[62,63]，支持向量机被广泛的运用于线性和非线性的分类问题中同时也可以做数据的回归分析，该算法能够有效的解决高维数据分类及小样本分类问题。该算法最重的是选择核函数和惩罚参数，核函数是数据的映射函数通常把数据从低维映射到高维，映射后的得到高维数据，通过找到数据的支持向量而确定最优的分割超平面用于对数据的分类。一般常用的核函数有，线性核、多项式核、径向基核等。惩罚参数的设置也会影响到实验的结果，它表示对错误分类的惩罚程度，过高的惩罚参数

会导致分类过拟合，过低的参数可能影响 SVM 对线性不可分数据的分类性能。本文在实验阶段选择 RBF 径向基核函数并且惩罚参数设置为 1。

(4) 朴素贝叶斯(naive bayes, NB)^[64]，朴素贝叶斯算法是一种基于统计学的分类的方法，只需要满足特征条件独立即可。通过计算已知所属类别的先验条件概率确定测试实例属于各类的后验概率。通过比较获得的后验概率大小分成不同的类别。该算法拥有完整数学原理支撑，并且易于理解。

(5) 线性判别算法(linear discriminant, LDA)^[65]，线性判别法是一种有监督的降维及分类技术。通过找到一种超平面使得同一类数据更加内聚，不同类之间的间隔更大。根据判别标准不同又可以分为距离判别、Fisher 判别、Bayes 判别等。

(6) 决策树(decision tree, DT)^[66]，决策树是一种非线性的分类器依据不同的判断规则选择不同的子集进行处理，实际是运用于分类的一种树结构，其中的每个内部节点代表对某一属性的一次测试，每条边代表一个测试结果，叶节点代表某个类或类的分布。决策树的决策过程需要从决策树的根节点开始，待测数据与决策树中的特征节点进行比较，并按照比较结果选择选择下一比较分支，直到叶子节点作为最终的决策结果。常用的决策树算法有 ID3 和 C4.5，本文中选择 C4.5 作为分类算法。

(7) 人工神经网络(artificial neural networks, ANN)^[67]，人工神经网络是一种模拟生物神经元信息传递的一种模式匹配算法，有很多的神经网络模型如：感知神经网络(perceptive neural network, PNN)、反馈网络、自组织映射网络等。在本文中选择的是 BP 前反馈网络。

2.5 本章小结

本章针对研究问题简单的介绍了所使用到的一些理论知识。包括对非线性复杂信号处理技术——经验模态分解(EMD)的介绍，介绍了经验模态把原信号分解成若干信号需要满足的条件，以及描述了具体的分解过程。同时根据脑电信号的非静态特性，介绍了传统的三种脑电熵特征提取算法，分别是排列熵，样本熵，模糊熵的特征提取算法。简单的说明了三种熵特征的优缺点，如排列熵特征的简单、高效，样本熵和模糊熵特征更有利于提高疲劳驾驶的分类准确率。最后简单的介绍了所使用的 7 种分类器的模型。

第 3 章 基于经验模态分解的自适应多尺度熵模型构建及算法描述

3.1 模型构建

本文研究的对象的是驾驶员的脑电，主要分析的也是驾驶员的脑波电信号数据。脑电是独立个体在某个时间点大脑内部状态的反应，可以有效的描述在该时间点驾驶员的大脑状态，通过这些状态可以有效的判别驾驶员是否处于疲劳驾驶，用于及时的提醒驾驶员注意休息。该模型如图 3.1 所示：

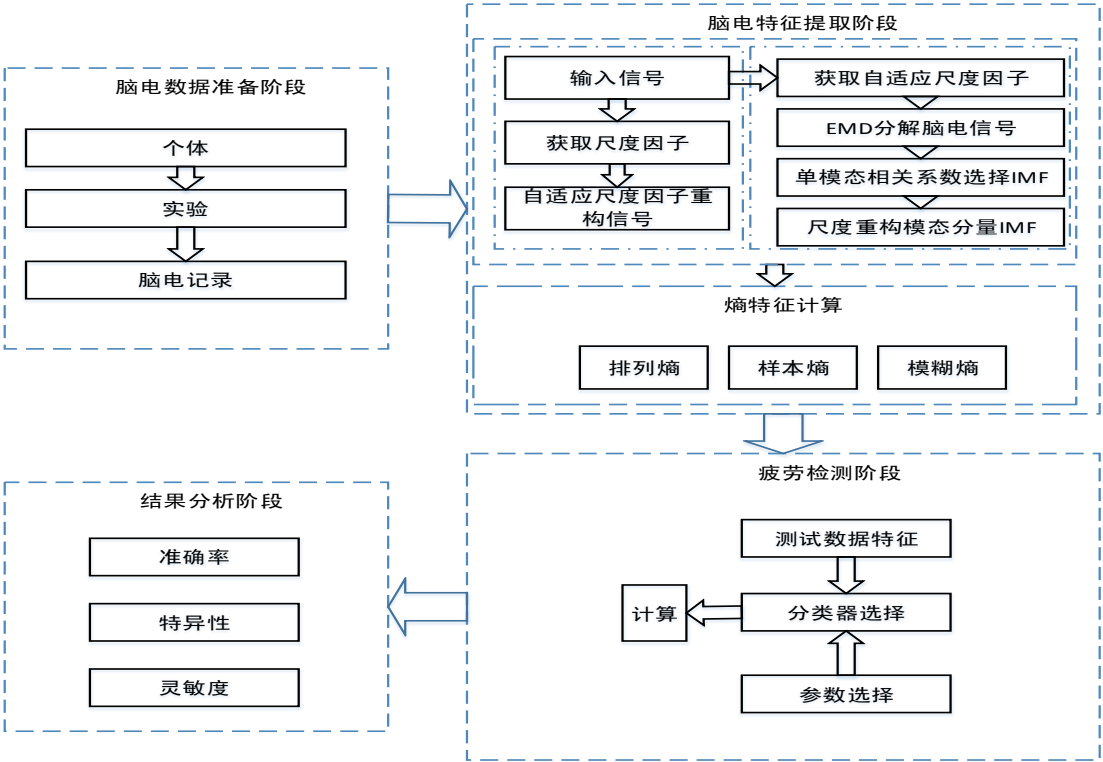


图 3.1 模型构建过程

图中包括以下 4 个部分：

- (1) 脑电数据准备阶段：包括脑电数据的采集，脑电的预处理(伪迹去除，干扰眼电去除，信号矫正等)。
- (2) 脑电特征提取阶段：主要包括自适应多尺度熵以及经验模态分解下的自适应多尺度熵。自适应多尺度熵，首先是通过自适应尺度算法求得自适应尺度

因子，然后根据自适应尺度因子重构信号得到各个重构后的信号，在计算它们的排列熵、样本熵及模糊熵得到相应的自适应多尺度熵特征。经验模态分解下的自适应多尺度熵，首先也是通过自适应尺度算法求得输入信号的自适应尺度因子，其次对输入信号采用经验模态分解技术分解，然后采用单模态分量系数选择相关模态，在用得到的自适应尺度因子重构得到的若干个相关模态生成新的时序信号，计算这些重构后的模态分量的排列熵、样本熵、模糊熵特征得到相应的经验模态分解下的自适应多尺度熵特征。

(3) 脑电疲劳检测阶段：分类实验，可选择多种分类器，设置相应分类器参数。

(4) 结果分析：计算准确率，特异性，灵敏度。

3.2 模型中的相关参数说明

模型构建过程中涉及到了很多参数，这里主要介绍在特征抽取阶段所涉及到的参数，对于采集阶段的参数说明在后面实验阶段作详细介绍。第三阶段所使用到的七种分类器在第二章介绍分类器的时候也做了简单的介绍这里就不过多的赘述。

在求样本熵、模糊熵特征时涉及到几个重要的参数，嵌入维数 m 、相识容限值 r 以及所分析信号数据的长度 N ，这三个值的大小会直接影响到所计算的熵特征值。由样本熵的原理可知，计算的熵值实则是求和的对数，这也是样本熵作为近似熵^[68]的一种改进而出现。它主要的目的也就是为了减少近似熵所带来的误差。它的两个主要的优点是，第一，样本熵不包含自身的数据段的比较，它是条件概率的负平均自然对数的精确值，它是不依赖与所计算的数据的长度的，因而也适合处理短时序数据；第二，样本熵表现出更好的一致性，即一时间序列比另一时间序列有较高的值的话，那对于它的 m 和 r 值也具有较高值。模糊熵是样本熵的一个改进用一个指数函数平滑对数和，因而也具备样本熵的特性，所以在取 m 和 r 的时候设置一样，Pincus曾指出 r 的取值为信号数据的标准差的0.1~0.25倍即(0.1~0.25SD, SD为标准差)， m 取1或2时所求的熵值对序列长度 N 的依赖性最好，表现为较好的统计特性。因而在本论文实验中样本熵和模糊熵的 m 都取2， r 都取0.2。排列熵的两个主要的参数一个是嵌入维数 m 另一个是延迟时间 τ ，这两个参数的值对排列熵计算结果影响最大，目前对于这

两个参数的取值也同样是依靠于经验的选择，这也是排列熵目前在工程上应用的一个主要的瓶颈，一般而言排列熵 m 的取值范围为 $1 \leq m! \leq N$ ， N 为数据的长度。在本次实验中数据的长度为1000， m 取最大值为6，经过多次实验发现 $m=6$ 实验效果较好，同时对于参数 τ 而言取1^[69]。

3.3 自适应尺度因子概念及算法描述

3.3.1 尺度概念

对于输入的信号 $Sig_n = \{u_i, 1 \leq i \leq n\}$ ，其中 n 为信号的长度，根据 Wu 等人的多尺度算法^[70]构建一个尺度为 s 的新的序列 $y_j^{(s)}$ 。具体的步骤表述如下：

(1) 确定一个步长为 s 的移动窗口，作为该序列的尺度因子，按顺序移动该窗口。如图 3.2 所示：

(2) 求出各个窗口 s 下的时间序列的均值，作为该尺度单位的序列值。

$$y_j^{(s)} = \frac{1}{s} \sum_{i=j}^{j+s-1} u_i, \quad 1 \leq j \leq n - s + 1 \quad (3.1)$$

其中 s 为尺度因子， n 为信号 Sig 的序列长度。




图 3.2 尺度粗化过程

尺度化的本质实际上就是对信号粗化的一个过程，不同尺度化后得到信号可以用于熵特征的计算，继而得到信号的多尺度熵特征。

3.3.3 自适应尺度因子算法(ASF)描述

确定信号的时间尺度，用于重构信号数据，并计算多尺度熵特征是一种有效的提高分类准确率的方法。然而在目前多尺度熵的研究中，还没有一种有效的方式确定信号的尺度信息，一般都是在每个尺度下，分别计算多尺度熵特征继而计算分类准确率确定尺度因子。采用这样的逐步实验法，虽然最终能够得到相对比较好的尺度因子，但是每一次计算都要求取相应的多尺度熵特征。而这一过程，对于相应的熵特征提取算法而言需要花大量的计算时间。这么高的时间复杂显然不符合实际的应用场合，因此本文研究如何在不事先计算多尺度熵特征的基础上，获取尺度因子的方法，提出了一种自适应尺度因子法(adaptive scaling factor, ASF)。该方法能够有效的确定序列的自适应时间尺度，以下是算法的具体步骤：

算法的输入：原始信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$

算法的输出：尺度因子 σ

- (1) 初始化尺度 $\sigma = 1$ ，设置距离阈值 $\varepsilon = C(C$ 通过实验确定)。
- (2) 根据尺度 σ 细粒度重构信号，得到重构后的信号 S_σ 。
- (3) 二值化信号 S_σ ，得到信号 S'_σ 。
- (4) 采用 kmeans 聚类算法，分别求得二值化信号 S'_σ 在疲劳和正常状态下的聚类中心 C_1, C_2 。
- (5) 求两个聚类中心的欧氏距离 $Dis = Distance(C_1, C_2)$ 。
- (6) 判断 Dis 和 ε 之间的大小，若 $Dis \geq \varepsilon$ ，则终止循环，转到步骤(8)；否则转步骤(7)
- (7) 执行 $\sigma = \sigma + 1$ ，则继续转到步骤(2)循环。
- (8) 输出有效尺度 σ
- (9) 结束。

算法的流程图如图 3.3 所示：

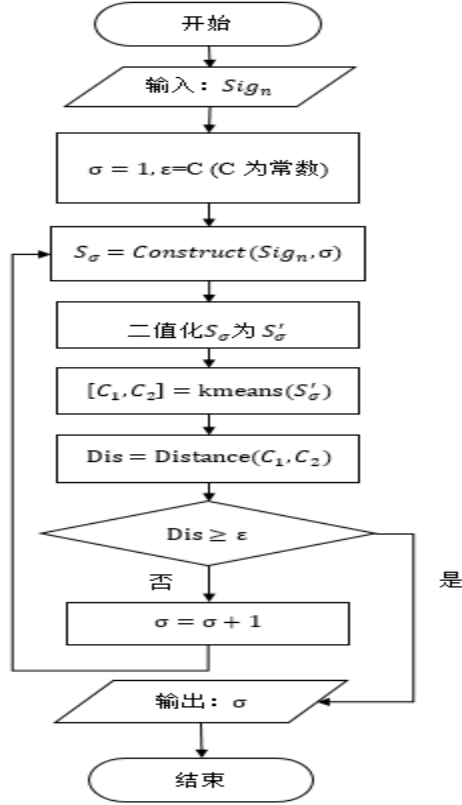


图 3.3 自适应尺度算法流程图

在以上算法步骤中，步骤(3)采用的方法是^[71]改进的 Lempel-Ziv 算法，一种自适应二值化算法，该算法包括以下两步：

(1) 计算脑电信号的二值化阈值 μ

给定脑电序列 $Sig_n = \{u_1, u_2, \dots, u_n\}$ ，其中 n 为节点数， μ 为除去最后一个节点后相邻节点差的平均值。即：

$$\mu = \frac{1}{n-1} \sum_{i=2}^{n-1} |x_i - x_{i-1}| \quad (3.2)$$

(2) 计算二值化值

(2.1) 计算序列 $Sig_n = \{u_1, u_2, \dots, u_n\}$ 的平均值，为 avg

(2.2) 比较序列的第一个点 u_1 与 avg 大小。

$$u_1 = \begin{cases} 0, & u_1 < avg \\ 1, & u_1 \geq avg \end{cases} \quad (3.3)$$

(2.3) 从第二点 u_2 开始，依次和前一个点比较，若当前值与前一个值差值的绝对值小于阈值 μ ，则当前值的二值化值与前一个点的二值化值一致；若当前值与

前一个差值的绝对值大于等于 μ ，则二值化根据与前面值的大小判定，公式如下：

$$u_i = \begin{cases} u_{i-1}, & |u_i - u_{i-1}| < \mu \\ 0, & |u_i - u_{i-1}| \geq \mu, u_i \leq u_{i-1} \\ 1, & |u_i - u_{i-1}| \geq \mu, u_i \geq u_{i-1} \end{cases} \quad (3.4)$$

二值化的目的也是为了在算法第5步计算欧几里得距离时，不会因为噪声大的异常信号点，影响到最后的距离计算，有效的解决了欧氏距离对大数敏感的问题。最后根据算法求得最大距离对应的尺度信息，为自适应尺度因子。

3.3.4 算法时间复杂度分析

该算法分析的是 $m \times n$ 阶的数据信号其中 m 可以定义为采样时间， n 可定义为采样频率。在任一个尺度下，重构需要的时间复杂度为 $O(m \times n)$ ，二值化需要的时间复杂度为 $O(m \times n)$ ，K-means 的算法复杂度为 $O(t \times m \times n \times k)$ ，其中 t 和 k 分别代表的是迭代次数以及聚类中心。在本研究的问题中疲劳和正常状态都是独立分析的，所以求疲劳状态和正常状态时的聚类中心时 k 都为 1，对于 t 而言都要远小于 m ， n 。所以整体而言，在求得自适应尺度因子需要的时间复杂度为 $O(t \times m \times n)$ 。

3.4 单模态分量相关(SIMFR)系数

脑电信号本身是一种非线性、非静态的时序数据信号，通常包含着大量的噪声数据。EMD 作为一种经典的信号处理方法，能够把信号分解成若干个固有模函数分量(IMFs)和单个信号余量，其中包含了有用数据信号和噪声信号。通常也没有一种固定的方法确定哪些为噪声数据，有相关学者直接把信号余量看做噪声数据。这样显得尤为不妥因为信号余量表示的是信号的单一性，即并不满足经验模态的分解条件的信号，并不能作为是噪声数据的依据。当然也有学者为了能够使各个模态分量之间更容易区分不会出现模态混叠的现象而添加了一些噪声数据如高斯白噪声等使得分解出来的信号包含更多有用的信号数据。本文定义一种单模态分量相关系数，该系数反应的是各分量与输入信号之间的相关性，以这种相关性选择需要处理的 IMF 分量。这样做的好处是既能够用 EMD 技术处理信号达到降噪的目的，又能够参照输入信号，保持输入信号原有的一些非线性特性。

3.4.1 单模态分量相关系数定义

定义：设有 N 个点的时序信号 $S_n = \{u_i, 1 \leq i \leq n\}$ ，经过经验模态 EMD 分解后得 $\{IMF_j + R\rho, 1 \leq j \leq K\}$ 其中 K 为分解的 IMF 的总数， $R\rho$ 为模态余量，模态相关系数 r ：

$$r_i = \frac{\sum_{ij}^n (IMF_{ij} - \overline{IMF_{ij}})(S_{ij} - \overline{S_{ij}})}{\sqrt{\sum_{ij}^n (IMF_{ij} - \overline{IMF_{ij}})^2 (S_{ij} - \overline{S_{ij}})^2}} \quad (1 \leq i \leq K + 1) \quad (3.5)$$

其中 r_i 表示第 i 个模态分量与输入信号 S_n 的相关系数， $\overline{IMF_{ij}}$ 为分量 IMF_{ij} 的均值， $\overline{S_{ij}}$ 为信号 S_{ij} 的均值。

3.4.2 模态选择指标

由于信号本身是非线性的，而以上所求的 r_i 表示的是一种弱线性相关。根据皮尔逊相关系数表可知：对于任意两个变量 X, Y ，它们之间的皮尔逊取值在 0.8~1.0 之间为强相关，0.6~0.8 为较强相关，0.4~0.6 为相关，0.2~0.4 为弱相关，0~0.2 为不相关。所以当 $r_i > 0.2$ 时即可以选择该 IMF_i 分量，表示该分量与输入信号之间存在弱相关性，也即表示该分量包含了信号需要处理的有用信息。把不满足该条件的分量作为无相关数据直接丢弃。

3.5 两种自适应多尺度排列熵算法描述

3.5.1 自适应多尺度排列熵特征算法

多尺度排列熵算法是在排列熵的基础之上增加了脑电信号的多时间尺度特征。本文对输入信号采用自适应尺度因子法计算它的尺度因子，根据尺度因子重新生成新的脑电信号，其详细的算法描述如下；

算法的输入：输入信号

算法的输出：自适应多尺度排列熵特征(AMPE)

- (1) 待处理的输入信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$
- (2) 根据自适应尺度因子算法(ASF)，计算信号 Sig_n 尺度因子 σ 。
- (3) 根据尺度信息重构生成新的信号 $y_l^{(\sigma)}$ ，其中 l 为新构成的信号的长度
- (4) 对重构信号 $y_l^{(\sigma)}$ ，采用排列熵算法计算特征
- (5) 输出自适应多尺度排列熵特征(AMPE)
- (6) 结束

算法的流程图如图 3.4 所示：

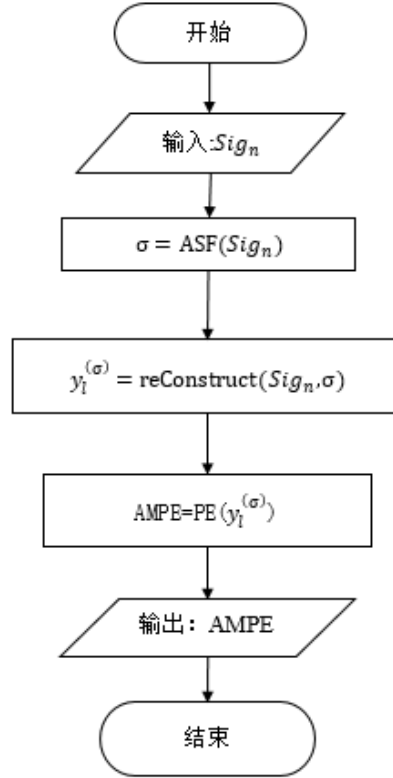


图 3.4 自适应多尺度排列熵算法流程图

3.5.2 基于经验模态分解的自适应多尺度排列熵特征算法

上面介绍了排列熵及自适应多尺度排列熵的算法。自适应多尺度排列熵在排列熵的基础上寻找自适应尺度因子，最后重构时序信号重新计算排列熵值。而基于经验模态分解的自适应排列熵特征抽取算法，首先需要对输入信号采用自适应尺度因子的方法求得自适应尺度。其次，对输入信号进行经验模态分解操作，分解后会得到一个模态分量集和一个剩余分量，然后使用单模态分量相关系数选择相关模态分量。再用自适应尺度因子重构选择的分量信号数据，生成新的分量集。最后，再分别对每个分量计算它的排列熵特征，其详细描述如下：

算法的输入：输入信号

算法的输出：基于经验模态分解自适应多尺度排列熵特征(IMF_AMPE)

- (1) 待处理的输入信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$
- (2) 根据自适应尺度算法(ASF)，计算原始信号的自适应尺度因子 σ

- (3) 用经验模态分解(EMD)算法处理 Sig_n ，得到 $IMFs = \{IMF_j + R\rho\}, j \in N, N$ 为正整数。
- (4) 设置 K 为 IMF 的数量加 1，即 $K = \text{len}(IMF) + 1, j = 1$
- (5) 判断 j 是否小于等于 K ，若 $j \leq K$ ，则继续执行；否则，跳转到步骤(10)。
- (6) 赋值 $S = IMF_j$ 或 $S = R\rho$ ，计算 S 和 Sig_n 的单模态相关系数 r 。
- (7) 判断 r 与 0.2 的大小，若 $r < 0.2$ ，则转到步骤(5)；若 $r \geq 0.2$ ，则该模态分量 S 与 Sig_n 若相关。
- (8) 根据尺度因子 σ 重构信号分量 S ，生成新的信号 $y_l^{(\sigma)}$ ，其中 l 为信号的长度。
- (9) 计算 $y_l^{(\sigma)}$ 的排列熵。转到步骤(5)
- (10) 退出循环，输出弱相关模态分量的自适应多尺度排列熵特征
- (11) 结束

算法的具体的流程图如图 3.5 所示：

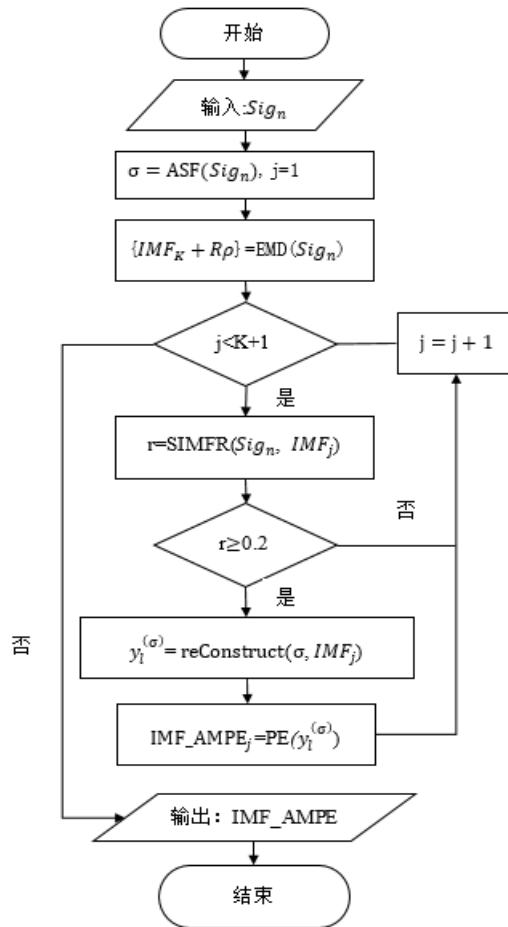


图 3.5 经验模态分析下的自适应多尺度排列熵流程图

3.5.3 算法时间复杂度分析

排列熵的算法的时间复杂度是由脑电时序信号的数据长度确定的为 $O(n)$ ，而在采样时间为 m 的情况下时间复杂度就为 $O(m * n)$ 。多尺度排列熵算法，在寻找自适应尺度因子时使用 k -means 算法迭代 t 次求聚类中心的距离，所以时间复杂度为 $O(t * m * n)$ 。而基于经验模态分解的信号成 k 个分量，计算相关模态分量得到相关的 k 个分量，因此时间复杂度为 $O(t * m * k * n)$ 。如表 3.1 所示。

表 3.1 排列熵相关算法时间复杂度

特征算法	时间复杂度
PE	$O(m * n)$, m 为采用时间, n 采样频率
AMPE	$O(t * m * n)$, t 为 k -means 迭代次数, m 为采样时间, n 采样频率
IMF_AMPE	$O(t * m * k * n)$, t 为 k -means 迭代次数, m 为采样时间, k 为 EMD 分量个数, n 采样频率

3.6 两种自适应多尺度样本熵算法描述

3.6.1 自适应多尺度样本熵特征算法

样本熵算法默认的是计算尺度为 1 的情况下的熵特征值。自适应多尺度样本熵特征提取算法是根据自适应尺度因子算法确定尺度信息，用于生成新的时间序列，得到的新的序列是加入尺度信息后的序列，之后就用样本熵计算序列的熵特征值，其详细的算法描述如下；

算法的输入：输入信号

算法的输出：自适应多尺度样本熵特征(AMSE)

- (1) 待处理的输入信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$
- (2) 根据自适应尺度因子算法计算信号 Sig_n 的自适应尺度因子 σ
- (3) 根据尺度算法重新生成新的信号 $y_l^{(\sigma)}$ ，其中 l 为新构成的信号的长度
- (4) 对重构信号 $y_l^{(\sigma)}$ ，采用样本熵算法计算特征
- (5) 输出自适应多尺度样本熵特征(AMSE)
- (6) 结束

算法的流程图如图 3.6 所示：

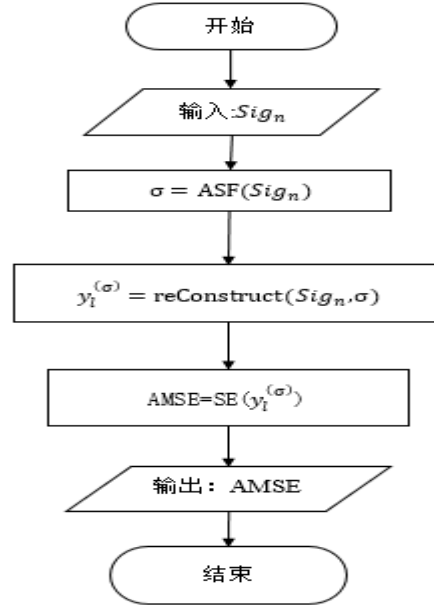


图 3.6 自适应多尺度样本熵算法流程图

3.6.2 基于经验模态分解的自适应多尺度样本熵特征算法

同经验模态分解的自适应多尺度排列熵一样。首先，用自适应尺度因子算法计算信号的自适应尺度。其次，用经验模态分解技术分解输入信号数据，并利用相关模态分量算法选择与输入信号相关的模态分量。在根据尺度信息重构选中的每个分量信号得到新的分量集信号。最后，计算这些重构后的分量的样本熵特征，不同的分量将得到不同多尺度熵值，具体算法描述如下：

算法的输入：输入信号

算法的输出：基于经验模态分解的自适应多尺度样本熵特征(IMF_AMSE)

- (1) 待处理的输入信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$
- (2) 根据自适应尺度算法(ASF)，计算原始信号的自适应尺度因子 σ
- (3) 用经验模态分解(EMD)算法处理 Sig_n ，得到 $IMFs = \{IMF_j + R\rho\}, j \in N, N$ 为正整数。
- (4) 设置 K 为 IMF 的数量加 1，即 $K = \text{len}(IMF) + 1, j = 1$
- (5) 判断 j 是否小于等于 K 。若 $j \leq K$ ，则继续执行(6)；否则，转到(10)。
- (6) 赋值 $S = IMF_j$ 或 $S = R\rho$ ，计算 S 和 Sig_n 的单模态相关系数 r 。
- (7) 判断 r 与 0.2 的大小，若 $r < 0.2$ ，则转到步骤(5)；若 $r \geq 0.2$ ，则该模态分量 S 与 Sig_n 若相关。

- (8) 根据尺度因子 σ 重构信号 S ，生成新的信号 $y_l^{(\sigma)}$ ，其中 l 为信号的长度。
- (9) 计算 $y_l^{(\sigma)}$ 的样本熵。转到步骤(5)
- (10) 退出循环，输出弱相关模态分量的自适应多尺度样本熵特征
- (11) 结束

算法的具体的流程图如图 3.7 所示：

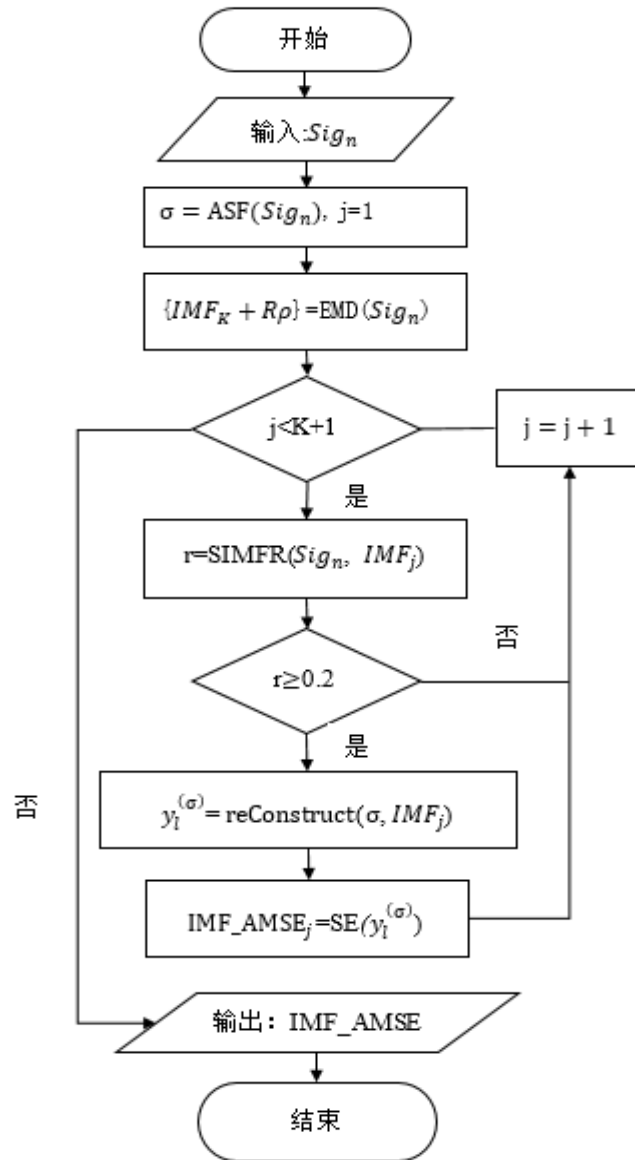


图 3.7 经验模态分析下的自适应多尺度样本熵流程图

3.6.3 算法时间复杂度分析

样本熵的时间复杂度相比于排列熵而言复杂度更高，所需要计算的时间更长。主要的原因是对于嵌入维数为 d 的时序序列，需要用 $O(n^2)$ 时间复杂度计算出所需要的熵值，而且对 $d + 1$ 维的重构又需要重复的计算一遍，因而时间复杂度提高更加明显，如表 3.2 所示。

表 3.2 样本熵相关算法时间复杂度

特征算法	时间复杂度
SE	$O(m * n^2)$, m 为采用时间, n 采样频率
AMSE	$O(t * m * n^2)$, t 为 k-means 迭代次数, m 为采样时间, n 采样频率
IMF_AMSE	$O(t * m * k * n^2)$, t 为 k-means 迭代次数, m 为采样时间, k 为 EMD 分量个数, n 采样频率

3.7 基于经验模态分解的自适应多尺度模糊熵算法描述

3.7.1 多尺度模糊熵特征算法

自适应多尺度模糊熵算法是对自适应多尺度样本熵方法的一种改进，改进的方式也就是同模糊熵对样本熵改进的方式一样，用模糊度函数替代原来的方式求距离，使得计算结果更加的平滑，其算法描述如下：

算法的输入：输入信号

算法的输出：自适应多尺度模糊熵特征(AMFE)

- (1) 待处理的输入信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$
- (2) 根据自适应尺度算法，计算信号 Sig_n 自适应因子 σ 。
- (3) 根据尺度因子重新生成新的信号 $y_l^{(\sigma)}$ ，其中 l 为新构成的信号的长度。
- (4) 对重构信号 $y_l^{(\sigma)}$ ，采用模糊熵算法计算特征
- (5) 输出自适应多尺度模糊熵特征(AMFE)
- (6) 结束

算法的流程图如图 3.8 所示：

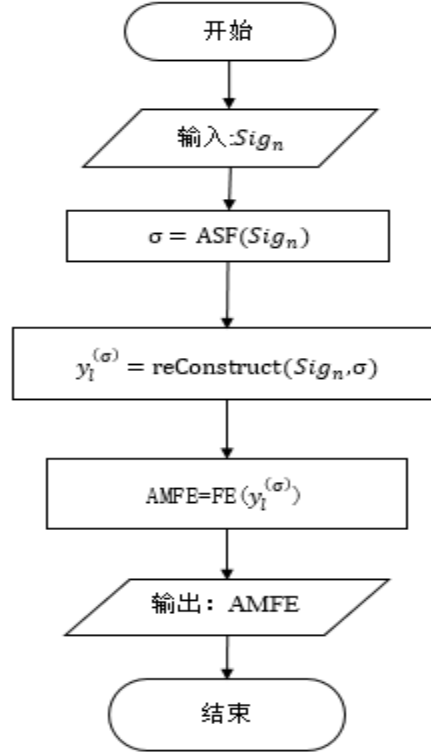


图 3.8 自适应多尺度模糊熵算法流程图

3.7.2 基于经验模态分解的自适应多尺度模糊熵特征算法

经验模态分解的自适应多尺度模糊熵特征同样是先求自适应尺度，然后对信号采用单模态分量相关系数求得相关模态分量。用自适应尺度重构选中的模态分量，分别计算各重构后分量的模糊熵特征，其算法详细如下：

算法的输入：输入信号

算法的输出：经验模态分解下的自适应多尺度模糊熵特征(IMF_AMFE)

- (1) 待处理的输入信号 $Sig_n = \{u_1, u_2, \dots, u_n\}$
- (2) 根据自适应尺度算法(ASF)，计算原始信号的自适应尺度因子 σ
- (3) 用经验模态分解(EMD)算法处理 Sig_n ，得到 $IMFs = \{IMF_j + R\rho\}, j \in N, N$ 为正整数。
- (4) 设置 K 为 IMF 的数量加 1，即 $K = \text{len}(IMF) + 1, j = 1$
- (5) 判断 j 是否小于等于 K 。若 $j \leq K$ ，则继续执行(6)；否则，转到(10)。
- (6) 赋值 $S = IMF_j$ 或 $S = R\rho$ ，计算 S 和 Sig_n 的单模态相关系数 r 。
- (7) 判断 r 与 0.2 的大小，若 $r < 0.2$ ，则转到步骤(5)；若 $r \geq 0.2$ ，则该模态

分量 S 与 Sig_n 若相关。

(8) 根据尺度因子 σ 重构信号 S ，生成新的信号 $y_l^{(\sigma)}$ ，其中 l 为信号的长度。

(9) 计算 $y_l^{(\sigma)}$ 的模糊熵。转到步骤(5)

(10) 退出循环，输出弱相关模态分量的自适应多尺度模糊熵特征

(11) 结束

算法的具体的流程图如图 3.9 所示：

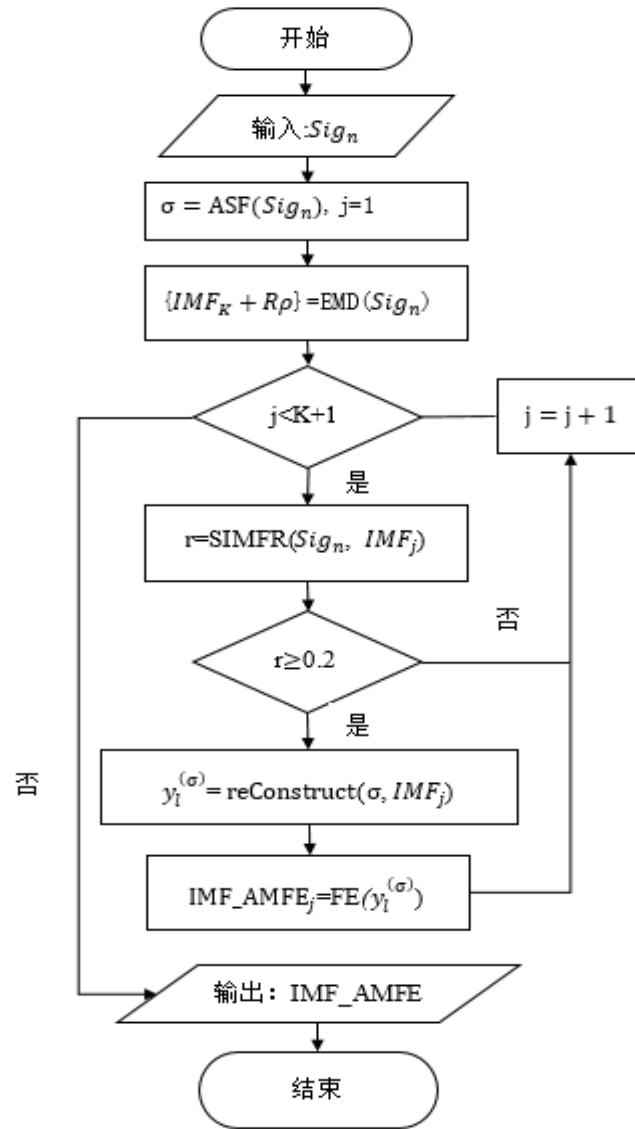


图 3.9 经验模态分解下的自适应多尺度模糊熵流程图

3.7.3 算法时间复杂度分析

模糊熵相关算法的时间复杂度同样本熵类似，在采样时间为 m ，采样频率为 n 时，时间复杂度为 $O(m * n^2)$ ，同样的对 AMFE 特征和 IMF_AMFE 特征抽取算法的时间复杂度都和样本熵类似如表 3.3 所示。

表 3.3 模糊熵相关算法时间复杂度

特征算法	时间复杂度
FE	$O(m * n^2)$, m 为采用时间, n 采样频率
AMFE	$O(t * m * n^2)$, t 为 k-means 迭代次数, m 为采样时间, n 采样频率
IMF_AMFE	$O(t * m * k * n^2)$, t 为 k-means 迭代次数, m 为采样时间, k 为 EMD 分量个数, n 采样频率

3.8 本章小结

本章主要介绍了模型的构建流程及构建过程时所需要的相应参数，同时也定义了两个概念，一个是有于模态分量选择的单模态相关系数(SIMFR)，另一个针对传统的多尺度熵算法难于确定尺度信息，提出了一种自适应获取尺度因子的算法(ASF)。接着分别介绍了自适应多尺度熵及基于经验模态分解的自适应多尺度熵算法分别是 AMPE、IMF_AMPE、MASE、IMF_MASE、AMFE、IMF_AMFE，以及绘制了相应的算法流程图并对算法所需要的时间复杂度做了简要的分析。

第 4 章 基于经验模态分解的自适应多尺度熵算法测试

4.1 实验预处理及性能评价

4.1.1 实验软硬件平台

实验用到的平台环境包括，一套静态的模拟驱动器(北京中育联合教学设备有限公司，ZY-31D 车辆驾驶模拟器)如图 4.1 所示，其中包括 3 块 24 英寸的显示器及一套驾驶模拟的软件教学系统(ZG-601 V9.2)。一套 32 电极的脑电采集帽，电脑系统采用的是 Windows7 x64。电脑硬件是 4GB 内存、500GB 的硬盘，脑电采集及预处理软件 Neuroscan 4.5，脑电分析软件 MATLAB2014a。



图 4.1 测试人员驾驶模拟系统

4.1.2 数据采集

实验前保证所有的实验个体在一周内没有生病，并且实验前一天晚上睡眠充足，没有食用如茶，功能饮料，酒水等物品。在实验时，实验管理员先介绍一下实验的操作流程，并让个体熟悉一下实验环境，包括周围的环境以及需要操作的模拟环境。实验辅助员需要重点介绍一下模拟驾驶系统的使用方法，待到实验个体熟悉所有的操作流程及操作规则后，也即准备工作结束。让实验者收复一下心情进入正常状态中。实验室辅助员用软件记录实验对象在静息状态

(正常状态)的脑电变化,记录时间为5分钟,把得到的5分钟数据作为静息状态下的脑电数据。之后实验对象进入正常的模拟驾驶状态,保证驾驶的时速控制在60到80km/h。由于不同的操作者进入疲劳的状态的时间不同,在一定时间的后让实验对象填写一张关于疲劳程度的调查表,该调查表主要是一些关于实验操作者在该时刻的一些身体感受调查,比如:是否感到四肢酸软、疲乏无力,是否感到注意力无法集中以及是否感到眼睛酸重发沉等。经过问卷统计后,若可以判断操作者已经进入了疲劳状态,此时可以由实验室辅助员用软件记录在该状态下操作者的脑电变化(此过程依然保持驾驶状态)。同样的记录时间为5分钟,得到操作者在疲劳状态下的脑电数据,实验数据采集结束。

4.1.3 数据预处理

通过专业脑电处理分析软件 Neuroscan 4.5 对原始脑电数据预处理分析,预处理过程中需要设置一些参数。如设置采样频率为 1000Hz,频率的宽度范围设置在 45Hz 的高通和 0.15Hz 的低通,把 A2 电极作为预处理的参考电极,采用 DC 模式进行分析等,主要包括以下几个步骤:

(1) 漂移脑电去除:在整个实验过程中难免会出现一些异常的情况,而导致脑电的漂移,需要采用人工的方式去除漂移的脑电。

(2) 去除眼电:在用 Neuroscan4.5 软件分析时找到比较明显的眼动,主要是垂直眼电(vertical eye),需要去除掉该眼电。因为眨眼伪迹是脑电信号采集过程中的常见噪声,会严重影响其有用信息的提取。

(3) 伪迹去除:使用 transform-artifact rejection 对脑电信号中的伪迹去除,根据经验选择时域 time,一般为+50 或者+-100 之间的数值。

(4) 周期采样:由于 EEG 信号是一个连续的时序信号,所以需要用不同的频率对数据进行采样,本实验用到的采样频率为 1000Hz。

(5) 基线矫正:对于处理后的一些数据可能没有出现在基线中,也就不好查看,所以一般需要使用两次基线矫正和一次线性矫正。

(6) 数字滤波:实验的采样频率范围是 0.05Hz 到 1000Hz,采用数字滤波技术是为了得到主要分析频段的信号数据。本文采用的是 1.5Hz 到 70Hz 带通过滤。

在经过数据预处理后,每个个体被分为正常状态和疲劳状态并且分别有 300 个样本,其中在正常状态下所分析得到的 Fp1 电极, Fp2 电极的脑电差分电压图如图 4.2 所示。

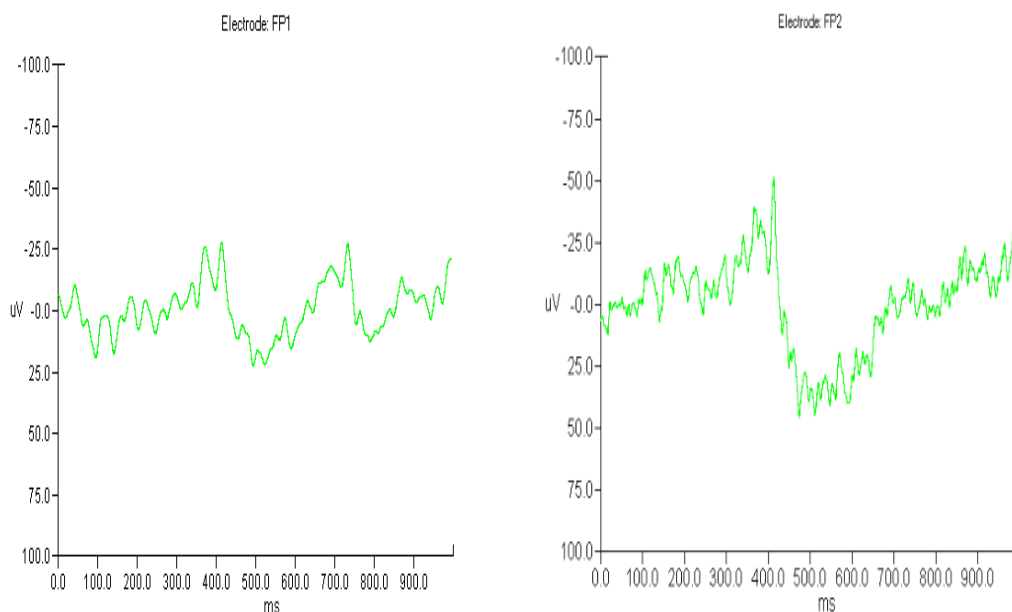


图 4.2 Fp1、Fp2 脑电极差分电位

4.1.4 实验个体选择

考虑到男性和女性在生理上的差异，容易导致脑电信号的强度及频率的变化影响实验结果。有学者针对男女性脑电波的差异分析，用脑电波成功运用于男女性别的判别^[72]。本节实验从采集得到的实验个体数中选取了 16 个实验个体，其中包括 8 个男性个体，8 个女性个体，用于验证性别因素对脑电疲劳驾驶的影响。表 4.1 和表 4.2 分别是 8 个男性个体和 8 个女性个体的实验结果。使用他们的前额导联(Fp1, Fp2)的脑电数据，采用传统的样本熵特征作为特征提取的方法对疲劳驾驶检测。每个个体数据选择 80% 做为训练集，20% 作为测试集采用支持向量机对数据进行分类实验，实验的次数都为 8 次。表格中 SM1~SM8 和 SW1~SW8 分别表示的是 8 个男性个体和 8 个女性个体，1~8 表示的是实验次数，Mean 和 Val 分别为平均值和均方差。

表 4.1 8 个男性个体选择(Fp1, Fp2)进行 8 次疲劳驾驶实验检测的分类准确率

	SM1	SM2	SM3	SM4	SM5	SM6	SM7	SM8
1	0.4711	0.6694	0.5620	0.4876	0.4628	0.4793	0.4711	0.4959
2	0.4793	0.5372	0.5455	0.4876	0.4793	0.4711	0.4959	0.4793
3	0.4298	0.5207	0.5455	0.5372	0.4463	0.4463	0.3967	0.4711
4	0.4711	0.5702	0.5950	0.4628	0.4711	0.4959	0.4298	0.4463
5	0.4876	0.4959	0.5785	0.5124	0.4959	0.4711	0.4711	0.4876
6	0.4463	0.5289	0.6116	0.5785	0.4628	0.4959	0.4545	0.4959
7	0.4959	0.4298	0.5537	0.5702	0.4711	0.4959	0.4545	0.4876
8	0.4959	0.6281	0.5620	0.5207	0.4959	0.4628	0.4711	0.4132
Mean	0.4721	0.5475	0.5692	0.5196	0.4731	0.4773	0.4556	0.4721
Val	0.0006	0.0057	0.0006	0.0017	0.0003	0.0003	0.0009	0.0008

表 4.2 8 个女性个体选择(Fp1, Fp2)进行 8 次疲劳驾驶实验检测的分类准确率

	SW1	SW2	SW3	SW4	SW5	SW6	SW7	SW8
1	0.4564	0.5372	0.4855	0.6017	0.6058	0.4876	0.6942	0.6942
2	0.5187	0.5868	0.4564	0.4730	0.6680	0.4876	0.6860	0.7025
3	0.4896	0.5744	0.5062	0.4813	0.5851	0.4628	0.6942	0.6198
4	0.4398	0.6488	0.4564	0.4647	0.6722	0.4959	0.7190	0.6198
5	0.4896	0.6653	0.4813	0.6183	0.5892	0.4711	0.7190	0.6198
6	0.4647	0.5661	0.4938	0.4730	0.6846	0.4793	0.7025	0.6612
7	0.4689	0.6653	0.4896	0.4689	0.5311	0.4793	0.7107	0.7025
8	0.5270	0.6570	0.5228	0.5021	0.5145	0.4711	0.7107	0.7025
Mean	0.4818	0.6126	0.4865	0.5104	0.6063	0.4793	0.7045	0.6653
Val	0.0009	0.0027	0.0005	0.0039	0.0042	0.0001	0.0002	0.0016

表 4.1 中可以发现男性第三个个体 SM3 对疲劳驾驶检测的平均检测率最高达 56.92%，第七个个体 SM7 对疲劳驾驶检测的平均检测率最低为 45.56%。八个男性个体的平均疲劳驾驶检测率为 49.83%，相应的均方差为 0.0017。在表 4.2 中发现女性第七个个体 SW7 对疲劳驾驶检测的平均检测率最高为 71.07%，第六个个体 SW6 对疲劳驾驶的平均检测率最低为 47.11%。八个女性个体的平均疲劳驾驶的检测率为 56.84%，相应的均方差为 0.0081。女性的平均疲劳检测率要比男性平均的疲劳检测率高出 7.01%。而且通过均方差及图 4.3 可知，不同个体之间的差异对疲劳驾驶的检测率是有影响的。在不同性别之间，八个女性个体对疲劳驾驶检测率的波动要比 8 个男性个体在疲劳驾驶检测中的波动要大，说明了男性

个体和女性个体由于生理因素的差异对疲劳驾驶的检测是有影响的。因此本文在后续实验中为了消除由性别因素带来实验结果的影响，而选择了对疲劳检测率较平稳的8个男性个体进行实验，即SM1~SM8作为后续实验的分析对象。

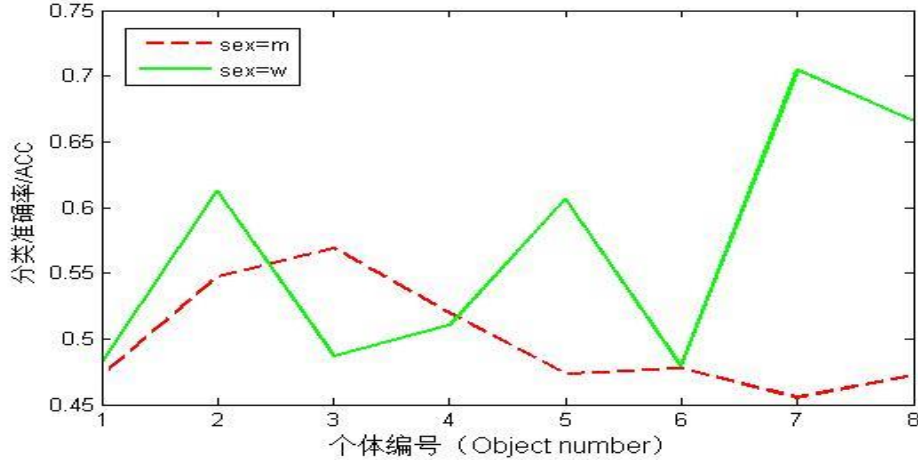


图 4.3 男女不同个体的前额导联对疲劳驾驶的平均检测准确率

4.1.5 性能评价矩阵

在机器学习中对于有监督的分类任务而言，混淆矩阵可以有效的判断一个分类算法的优劣。根据矩阵绘制而成的 ROC、AUC 曲线也更加方便的让我们选择一个好的分类器。通过矩阵中的数据我们能够计算出一些性能指标如：准确率，敏感度，特异性，马太系数等^[73]，它们的描述如下：

$$Acc = \frac{TP+TN}{TP+TN+FP+FN} \quad (4.1)$$

$$Sn = \frac{TP}{TP+FN} \quad (4.2)$$

$$Sp = \frac{TN}{TN+FP} \quad (4.3)$$

$$Mcc = \frac{TP \times TN - FP \times FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \quad (4.4)$$

4.2 自适应尺度因子及相关模态分量的选择

4.2.1 尺度因子的确定

信息尺度的大小没有一个统一的标准；因为尺度过大，导致信息量减少过多以至于重构得到新的信号不能很好的表述原问题信息，尺度选择过小也不能

充分的利用尺度信息。本实验根据采样频率的 20% 选择尺度的范围，即最大尺度为 200。并根据自适应的多尺度算法，分别计算电极 Fp1、Fp2 自适应尺度因子对应的疲劳状态和正常状态，这两个类别聚类中心的距离散点图，以及根据分布的散点图，求得小于某距离下散点的个数所对应的概率取值的折线图，如图 4.4、4.5 所示。其中(a)为实验 10 次所绘制的自适应尺度因子下，疲劳状态和正常状态对应类别之间的聚类中心距离的散点图，(b)是根据散点图中的散点的分布，统计得到的小于某个距离值的概率曲线图。




图 4.4 Fp1 散点图和概率曲线




图 4.5 Fp2 散点图和概率曲线

图 4.4(a)中有 2000 个点，表示的是 10 次实验，每次求 1~200 尺度内对应的正常状态和疲劳状态聚类中心的距离散点分布图。图中的所有点表示的距离

都小于 1.2，都大于 0.2。所有的散点数中小于某距离值的概率如(b)所示，在距离小于 1.03 时，对应的概率取值为 99%，即散点图中有 1980 个点的距离小于 1.03。图 4.5(a)同样有 2000 个点，表示的是正常状态和疲劳状态聚类中心的距离的散点分布图。图中所有点表示的距离都小于 2.2，都大于 0.2。对应得到的概率曲线如(b)所示，在距离小于 1.76 的时候，对应的概率取值为 99%。因此，本文研究中选着 Fp1 的阈值 $\varepsilon \geq 1.03$ ，在尺度 $\delta = 33$ 时求得的正常状态和疲劳状态之间的聚类中心的距离首次超过该阈值，即电极 Fp1 得到的自适应尺度因子为 33。同样的选择 Fp2 的距离阈值 $\varepsilon \geq 1.76$ ，在尺度 $\delta = 14$ 时求得的正常状态和疲劳状态之间的聚类中心的距离首次超过该阈值，即电极 Fp2 得到的自适应尺度因子为 14。之后对疲劳驾驶的检测求得的自适应多尺度熵都将用相应电极的自适应尺度因子重构信号，之后计算相应的熵值。另外，选择德国 Bonn 大学癫痫病研究中心^[74]脑电信号进行测试。该数据集包含 A、B、C、D、E 五个子集，每个子集有 100 段脑电信号，每段信号由 4097 个采集点组成，采样的时间为 23.6s，采样的频率为 173.6Hz。A、B 子集分别表示 5 名健康自愿者在睁眼和闭眼状态下采集的脑电数据；C、D 分别是 5 名癫痫患者在癫痫发作间期在病灶外和病灶内采集的脑电数据集；E 为上述五名患者在癫痫发作期采集的脑电数据集。本文研究为了正确的区分正常人和癫痫病患者，选择子集 A、B 作为正常人的脑电数据集，D、E 作为癫痫病患者的脑电数据进行测试。图 4.6，为癫痫数据集得到散点和概率曲线图，(a)散点图中有 350 个数据点，表示正常人和癫痫患者聚类中心之间的距离散点分布。图中所有点距离范围为 3.6 到 5.0 之间，所有的散点小于某距离值的概率如曲线(b)所示。在距离小于 4.25 时，对应的概率取值为 99%，所以本次实验设置的距离阈值为 $\varepsilon \geq 4.25$ 。在实验时，求得自适应尺度 $\delta = 12$ 时得到的正常人和癫痫患者之间的聚类中心距离首次超过该阈值，即癫痫脑电的自适应尺度因子为 12。抽取相应的单尺度模糊熵特征和对应的自适应多尺度模糊熵特征得到的检测准确率如表 4.3 所示：




图 4.6 Bonn 散点图和概率曲线

表 4.3 不同尺度下检测准确率

	Fp1 ($\delta = 1$ or 33)	Fp2 ($\delta = 1$ or 14)	Bonn ($\delta = 1$ or 12)
单尺度	0.5636	0.5515	0.8086
多尺度	0.5954	0.9517	0.9704

由表可知电极 Fp1 在单尺度的时候对疲劳驾驶检测率为 56.36%，通过自适应尺度算法获得的尺度为 33，重构原数据信号并抽取模糊熵特征得到的疲劳驾驶准确率达 59.54%，准确率提高了 3.18%。同样的，电极 Fp2 在单尺度下的疲劳检测率为 55.15%，自适应得到尺度为 14，重构脑电信号对疲劳驾驶检测的准确率为 95.17%，提高了 40.02%。针对 Bonn 癫痫病数据集而言，在尺度为 1 的时候抽取模糊熵特征得到的癫痫病检测率为 80.86%，自适应获得尺度为 12 的情况下，重构信号再抽取模糊熵特征得到癫痫病检测率为 97.04%，提高了 16.18%。通过自适应获得的尺度重构时序数据后都提高了相应的检测准确率，因而也证明了自适应尺度算法的有效性。

4.2.2 相关模态分量的选择

由于实验分析的是前额电极数据即 Fp1、Fp2 的电极数据，如图 4.7 所示，分别表示 Fp1、Fp2 采用经验模态分解的技术分解后得到的各个模态分量图。(a) 为 Fp1 在正常状态下使用经验模态分解，(b) 为 Fp2 在正常状态下的经验模态分解图，(c) 为 Fp1 在疲劳状态下的经验模态分解图，(d) 为 Fp2 在疲劳状态下的经

验模态分解图。图中的 Fp1、Fp2 表示原始信号，IMF1~IMF7 表示的是 7 个模态分量。对于每个电极的所有分量而言，IMF1 属于高频的分解信号，到 IMF7 信号基本趋于一条水平直线，作为余量进行处理。根据单模态分量相关系数，需要在这七个分量中选择若干个与原始信号相关的几个信号，通过计算各个分量的单模态相关系数值如表 4.4 所示，通过表格中的值发现 IMF1、IMF2、IMF3、IMF4、IMF5、IMF6 这 6 个分量与相应的原始信号的单模态相关系数值都大于 0.2。它们之间存在弱相关性，在后面的基于经验模态分解的自适应多尺度特征提取时选择这 6 个分量进行自适应多尺度熵特征的计算。




图 4.7 前额电极 Fp1, Fp2 经验模态分解后的各个分量

表 4.4 各分量与原始信号的单模态相关系数值

	IMF1	IMF1	IMF3	IMF4	IMF5	IMF6	IMF7
FP1(normal)	0.3871	0.4308	0.3587	0.2999	0.2912	0.2555	0.1187
FP2(normal)	0.3625	0.4296	0.3724	0.3400	0.3109	0.2510	0.1299
FP1(fatigue)	0.3128	0.3366	0.3027	0.3657	0.3688	0.2738	0.1548
FP2(fatigue)	0.2951	0.3455	0.3124	0.3403	0.3900	0.2888	0.1610

4.3 熵特征算法在检测疲劳驾驶中测试

4.3.1 多尺度熵特征对疲劳驾驶的检测

本节实验对 8 个男性个体的前额电极组成的数据集随机抽取 20% 作为训练集、80% 作为训练集。首先采用传统的熵特征提取算法提取数据特征，得到单尺度下的特征值(PE、SE、FE)。其次，在 4.2.1 节根据自适应尺度因子算法 (ASF) 求得的 Fp1 尺度因子为 33，Fp2 尺度因子为 14，使用相应的尺度因子重构原始信号得到自适应多尺度下的信号数据，接着采用三种熵特征算法提取特征得到自适应多尺度下的熵特征值(AMPE、AMSE、AMFE)。最后，在支持向量机下分别用 PE、SE、FE、AMPE、AMSE、AMFE 这些特征对疲劳驾驶分类检测。实验 10 次求平均分类准确率得到疲劳驾驶分类准确率如表 4.5 所示，绘制成的柱状图如图 4.8 所示：

表 4.5 前额电极下的疲劳驾驶检测准确率

Electrode	PE	SE	FE	AMPE	AMSE	AMFE
Fp1	0.6032	0.5122	0.5636	0.6412	0.6770	0.5954
Fp2	0.6557	0.5044	0.5515	0.7692	0.8583	0.9517
Fp1+Fp2	0.6820	0.5519	0.6386	0.8074	0.8804	0.9537




图 4.8 单尺度熵特征与自适应多尺度熵特征下对疲劳驾驶检测的准确率

由表 4.5 数据可知，在单尺度熵特征情况下，使用电极 Fp1 数据得到的 PE 特征对疲劳驾驶检测准确率最高达 60.32%，使用电极 Fp2 数据得到的 PE 特征对疲劳驾驶检测的准确率最高达 65.57%，组合电极下使用 PE 特征对疲劳驾驶检测的准确率最高达 68.20%。在自适应多尺度的情况下，Fp2 及组合电极采用 AMFE 特征得到疲劳驾驶检测的准确率要高于相应的 AMPE、AMSE 特征对疲劳驾驶的检测准确率，其中组合电极下的 AMFE 特征对疲劳驾驶的检测准确率最高达 95.37%。由图 4.8 可知，对于使用相同电极数据对疲劳驾驶的检测显示采用自适应多尺度熵特征相比于单尺度特征对疲劳驾驶的检测有明显的提高。电极 Fp1 采用 AMFE 对疲劳驾驶的检测率提高了 18.87%，电极 Fp2 采用 AMFE 特征对疲劳驾驶的检测率提高了 40.02%，组合电极采用 AMFE 特征对疲劳驾驶的检测率提高了 31.51%。由此可见，单尺度的信号采用自适应尺度因子算法得到的尺度因子，用于重构信号数据后能够有效的提高疲劳驾驶检测的准确率。

4.3.2 基于经验模态分解的多尺度熵特征对疲劳驾驶的检测

本节实验主要分为以下几步：第一步，采用经验模态分解的方法对输入信号进行经验模态分解操作，得到一系列的固有模态分量和一个余量。第二步，采用单模态分量相关系数选择与输入信号相关的k个分量，其中余量也作为特殊的分量参与计算。第三步，根据相应电极求得的原始信号的尺度因子(Fp1 尺度因子为 33，Fp2 的尺度因子为 14)重构第二步中选择的k个分量信号数据。第四步，采用熵特征提取算法计算第三步重构后的各个相关分量的熵特征值得到经验模态分解下的自适应多尺度排列熵(IMF_AMPE)特征、经验模态分解下的自适应多尺度样本熵(IMF_AMSE)特征以及经验模态分解下的自适应多尺度模糊熵(IMF_AMFE)。第五步把得到的特征数据集的 20%作为测试集、80%作为训练集，并选择支持向量机(SVM)作为分类器，通过 10 次实验求得疲劳驾驶的平均分类准确率如表 10 所示。其中采用 IMF_AMSE 特征，在组合电极(Fp1+Fp2)下得到的疲劳驾驶的检测准确率最高为 99.78%，比 IMF_AMPE 和 IMF_AMFE 对疲劳驾驶的检测率分别高 0.3 %和 0.5%。为了比较自适应多尺度熵特征算法和经验模态分解下的自适应多尺度熵特征算法，根据表格 4.5 中的自适应多尺度的分类准确率和表格 4.6 计算得到的分类准确率绘制成的柱状图如图 4.9 所示。由图可知，在相同电极数据下经过经验模态技术处理后得到的自适应多尺度熵特征算法都比经验模态分解处理前对疲劳驾驶的检测率要高，

因而通过实验结果可以说明经验模态分解的自适应多尺度熵特征算法要优于自适应多尺度熵特征算法对疲劳驾驶的检测。

表 4.6 基于经验模态分解下的自适应多尺度熵特征的疲劳驾驶分类准确率

Electrode	IMF_AMPE	IMF_AMSE	IMF_AMFE
Fp1	0.8347	0.8556	0.9577
Fp2	0.9755	0.9965	0.9846
Fp1+Fp2	0.9975	0.9978	0.9973




图 4.9 自适应多尺度与经验模态分解下自适应多尺度熵对疲劳驾驶检测准确率

4.3.3 基于经验模态分解的多尺度熵特征在多种分类器下的测试

为了消除不同分类器差异的影响，本文选择经验模态分解下的多尺度熵作为特征数据使用了 7 种分类器: 随机森林(RF), k 近邻(KNN), 支持向量机(SVM), 朴素贝叶斯(NB), 线性判别分析(LDA), 决策树(DT), 人工神经网络(ANN) 对疲劳驾驶分类检测得到的 ROC 曲线如图 4.10 所示:




图 4.10 不同分类器下的疲劳驾驶的检测

其中(a)是前额组合电极的 IMF_MPE 特征在 7 种分类器下的 ROC 曲线, (b)是前额组合电极的 IMF_MSE 特征在 7 种分类器下的 ROC 曲线, (c)是前额组合电极的 IMF_MFE 特征在 7 种分类器下的 ROC 曲线。计算得到各特征下的 AUC 值如表 4.7 所示

表 4.7 经验模态分解下的多尺度特征对于不同分类器计算得到的 AUC 值

	RF	KNN	NB	SVM	LDA	DT	ANN	Mean
IMF_AMPE	0.9872	0.9420	0.9841	0.9921	0.9910	0.9753	0.9842	0.9794
IMF_AMSE	0.9935	0.9905	0.9997	0.9978	1.0	0.9922	0.9980	0.9960
IMF_AMFE	0.9962	0.9874	0.9983	0.9964	1.0	0.9044	0.9576	0.9772

通过表 4.7 可知, IMF_AMFE 和 IMF_AMSE 在线性判别法(LDA)分类器下的效果最佳, AUC 的值达 1.0。同样, IMF_AMPE 特征在支持向量机(SVM)分类器下效果最好, AUC 值为 0.9921, 比在 LDA 分类器下的 AUC 的值高 0.1%。所以综合考虑而言线性判别(LDA)分类器对于各经验模态分解的自适应熵特征

的分类效果最好。计算前额组合电极在 7 种分类器下, 采用三种经验模态分解下的自适应多尺度熵特征得到的分类准确率、敏感度、特异性以及马太系数如表 4.8、4.9、4.10 所示。

表 4.8 IMF_AMFE 特征在 7 种分类器下的评价指标

Classifier	Acc	Sn	Sp	MCC
RF	0.9669	0.9833	0.9508	0.9344
KNN	0.9421	0.9846	0.8929	0.8860
NB	0.9752	0.9815	0.9701	0.9501
SVM	0.9669	0.9818	0.9545	0.9341
LDA	0.9917	1.0	0.9836	0.9836
DT	0.9256	0.9091	0.9455	0.8517
ANN	0.8843	0.9545	0.8000	0.7709
Average	0.9504	0.9707	0.9282	0.9015

表 4.9 IMF_AMPE 特征在 7 种分类器下的评价指标

Classifier	Acc	Sn	Sp	MCC
RF	0.9752	0.9692	0.9821	0.9503
KNN	0.8512	0.8571	0.8448	0.7020
NB	0.9669	0.9464	0.9846	0.9339
SVM	0.9669	0.9836	0.9500	0.9344
LDA	0.9917	1.0	0.9831	0.9836
DT	0.9752	0.9833	0.9672	0.9505
ANN	0.9587	0.9836	0.9333	0.9184
Average	0.9551	0.9605	0.9493	0.9104

表 4.10 IMF_AMSE 特征在 7 种分类器下的评价指标

Classifier	Acc	Sn	Sp	MCC
RF	0.9504	0.9559	0.9434	0.8993
KNN	0.9835	0.9825	0.9844	0.9668
NB	0.9917	1.0	0.9825	0.9835
SVM	0.9917	1.0	0.9831	0.9836
LDA	0.9917	0.9831	1.0	0.9836
DT	0.9917	0.9844	1.0	0.9836
ANN	0.9504	0.8824	1.0	0.9015
Average	0.9787	0.9697	0.9848	0.9574

不同的分类器对疲劳驾驶的检测存在一定的影响。组合电极数据下，采用线性判别分类器(LDA)对三种经验模态分解下的自适应熵特征得到的疲劳驾驶检测率最高都为 99.17%。这 7 种分类器下采用 IMF_AMFE、IMF_AMPE、IMF_AMSE 得到的平均分类准确率分别为 95.04%，95.51%，97.87%。

通过以上的分析得到的结果是，经验模态分解的自适应多尺度熵特征是能够有效地用于检测疲劳驾驶的。而且对于传统的熵特征添加尺度信息并用经验模态分解技术处理后能够得到的更高的疲劳驾驶检测率。表 4.11 也有一些其它学者的研究成果，采用不同电极和使用不同的方法计算得到的疲劳驾驶检测率。Hu^[13]、和 Mu^[43]等人没有考虑多尺度的信息对疲劳驾驶的检测，而直接采用单尺度的模糊熵算法提取信号特征，检测的平均准确率分别为 96.6%和 85.0%，他们不同的是对不同的脑电极进行分析，因而表现出来的差异性也特别明显。Zhang^[68]等人采用近似熵特征对电极 O1、O2 进行分析可以实时的对脑电进行分析。本文分析的前额电极 Fp1、Fp2，可知本文采用的经验模态分解下的自适应多尺度方法比单纯的使用熵的分析效果都要好。在实际运用中只要训练好模型，并设计一种类似于发夹一样的东西戴在前额就能完成驾驶员的脑电实时检测，对提高驾驶员的生命安全非常有意义。

表 4.11 不同研究对比

REARCH GROUPS	METHOD	EEG Electrode	Average Acc(%)
Hu ^[13]	Fuzzy entropy	CP4	96.6
Mu ^[43]	Fuzzy entropy	Fp1,Fp2	85.0
Zhang ^[68]	Approximate entropy	O1,O2	96.5
This Paper	Multi-scale sample entropy based on EMD method	Fp1,Fp2	97.87

4.4 本章小结

本章主要是对相应的模型测试实验，开始先简单的介绍了一下实验的平台及数据的采集，而后对采集数据简单的介绍了一下使用 Neuroscan 软件做预处理。紧接着用一个小实验确定研究对象为男性个体，后面又用两个实验说明了一下本文的模型用到的最重要的两个参数即尺度因子及单模态相关系数。最后在单尺度熵特征算法、自适应多尺度熵特征算法及经验模态分解下的自适应多

尺度熵特征算法分别对疲劳驾驶进行检测。并分析在不同的分类器下采用不同的特征计算疲劳驾驶的检测准确率。

第5章 总结与展望

脑电是某个时刻的大脑内部状态的反应，目前在医学领域内得到广泛的应用。人的疲劳对应到人脑电的变化是脑电频率变低，幅度变小。因而这种区别于正常状态下的脑电变化特征是能够用于疲劳驾驶的检测，又由于脑电本身是一种非静态、非平稳的时序信号存在着一系列特征的提取算法如排列熵、样本熵、模糊熵等，本文在这些传统的脑电熵特征提取的算法的基础上，分析人的前额脑电提出了一种基于经验模态分解的自适应多尺度熵特征提取算法，得到了如下结论：

(1) 男性个体使用前额脑电对疲劳驾驶检测在稳定性上要优于女性个体，但对女性的前额脑电的疲劳驾驶检测的准确率要高于男性，从这反面考虑男性个体和女性个体的这种生理因素的差异对疲劳驾驶的检测是有影响的。

(2) 本文提出了自适应尺度因子法确定熵特征的尺度信息，得到脑电测试数据 Fp1、Fp2 的自适应尺度因子分别是尺度 33 和 14。使用自适应尺度重构信号后，计算出相应的自适应多尺度排列熵 AMPE、自适应多尺度样本熵 AMSE、自适应多尺度模糊熵特征 AMFE 能够有效的提高疲劳驾驶检测的准确率，其中组合电极下的 AMFE 特征对疲劳驾驶的检测准确率最高达 95.37%。

(3) 经验模态作为一种有效的信号预处理方法。本文从脑电信号着手采用经验模态技术预处理信号，并基于此提出单模态分量相关系数用于选择与输入信号相关的若干模态分量用作自适应多尺度熵的输入信号。再提取自适应多尺度熵特征也即经验模态分解下的自适应多尺度熵特征(IMF_AMPE、IMF_AMSE、IMF_AMFE)，发现这些特征相比于自适应多尺度熵特征又能够进一步的提高对疲劳驾驶检测的准确率。其中采用 IMF_AMSE 特征，在组合电极(Fp1+Fp2)下得到的疲劳驾驶的检测准确率最高为 99.78%，比 IMF_AMPE 和 IMF_AMFE 对疲劳驾驶的检测率分别高 0.3 %和 0.5%。

(4) 本文为了排除单一的分类器对实验结果的影响，选择了七种分类器用做疲劳驾驶分类的检测，分别是 RF、KNN、NB、SVM、LD、DT、ANN。综合对比发现使用线性判别(LDA)分类器对实验的检测效果最好。

本文虽然采用基于经验模态分解的多尺度熵特征能够用于疲劳驾驶的检测，并且相比于单尺度熵、自适应多尺度熵能够明显的提高了疲劳驾驶的检测准确

率，但是依然存在以下限制：(1)本文为排除生理上的因素差异选择了所有个体为男性的样本进行实验，没有使用女性个体对实验进行验证，后期将使用同样的方法对实验个体为女性的样本以及混合男女个体进行测试分析。(2)本实验选择的个体实验数不多，后期将增加更多的实验的个体数，拓宽实验个体的年龄区间用于训练模型。(3)本文选择的经验模态分解技术作为信号的预处理，还有一些对经验模态分解技术改进的算法如集合经验模态分解等也可以引入用于分析脑电信号。(4)本文在多种熵特征中只选择了三种熵用于分析，后期将选择更加丰富的特征提取算法用于前额脑电的疲劳驾驶的检测。(5)本文研究的阈值距离 ϵ ，还没有一种更有效的方式确定，需要通过大量的实验求得，后期将对求取该阈值的方法做些尝试性改进。

致谢

三年前，满怀憧憬的进入了研究生的学习阶段。如今，三年的研究生生活也即将结束。这三年来不仅收获了知识、更多的还有感动与感谢。

首先，感谢我的导师邱老师。邱老师不仅是自己学业上的导师，更是生活中的导师。老师学识渊博、学术严谨，在每次讨论交流的时候，总是能直指问题所在。批改论文也总是孜孜不倦、字字斟酌，常教导我们对于研究要稳中求进、要学会思辨，要做具体的有意义的事情，不然让知识停留在理论，要在实践中检验。生活中也给予了我们很多的帮助，教导我们认真对待的每一件事，对我们总是那么的有耐心、那么的包容，也许这就学术人的魅力所在，甚是感动。

其次，感谢师兄肖永峰、师姐余宇婷。师兄是技术达人，碰见技术难题找师兄总能找到解决的办法。师姐好强、坚韧的性格也很是令人佩服。还有感谢实验室其他小伙伴金文、王贺、刘喆玥以及各位师弟师妹们，谢谢你们在生活中给我带来的欢乐，让实验室充满着欢声笑语，还有室友刘波、龙毅、陆克强以及好友叶修强、姜尹楠、苏燕飞、谢奕晨、班长方杰，以后在一起吃饭的日子是一天少一天了，谢谢你们给予的帮助，让生活充满乐趣。

最后，感谢父母。这读书二十来，你们是我人生中的指路人，这一路也少让你们操心，你们辛苦了。我将带着你们的教导、鼓励，砥砺前行。

刘超

2018年3月

参考文献

- [1] 王卓, 江国虹. 我国道路安全弱势人群的道路交通伤害现状[J]. 中国慢性病预防与控制, 2016, 24(1):71-73.
- [2] 龚标. 我国道路交通事故技术鉴定现状及对策[J]. 道路交通科学技术, 2017(3):3-6.
- [3] 赵晨. 我国重特大道路交通事故特征分析及对策[J]. 现代职业安全, 2017(4):20-23.
- [4] 张丽霞, 刘涛, 潘福全, 等. 驾驶员因素对道路交通事故指标的影响分析[J]. 中国安全科学学报, 2014, 24(5):79-84.
- [5] 翟景峰, 何辉. 公路交通行业安全生产网格化管理探索[J]. 中国公路, 2017(23):88-89.
- [6] 黄锦标, 张灵聪, 许炯泽. 基于脑电信号的驾驶疲劳研究[J]. 人类工效学, 2015, 21(4):36-40.
- [7] 李都厚, 刘群, 袁伟, 等. 疲劳驾驶与交通事故关系[J]. 交通运输工程学报, 2010(2):104-109.
- [8] Bourmaud A, Anot A, Moncharmont C, et al. Cancer-related fatigue management: evaluation of a patient education program with a large-scale randomised controlled trial, the PEPs fatigue study[J]. British Journal of Cancer, 2017, 116(7): 849-858.
- [9] Hoddes E, Zarcone V, Smythe H, et al. Quantification of sleepiness: a new approach.[J]. Psychophysiology, 1973, 10(4):431.
- [10] Janssen K C, Phillipson S, O'Connor J, et al. Validation of the Epworth Sleepiness Scale for Children and Adolescents using Rasch analysis[J]. Sleep Medicine, 2017, 33(3): 30-35.
- [11] Moruzzi G, Magoun H W. Brain stem reticular formation and activation of the EEG[J]. Electroencephalography and clinical neurophysiology, 1949, 1(1): 455-473.
- [12] Phillips H A, Scheffer I E, Crossland K M, et al. Autosomal dominant nocturnal frontal-lobe epilepsy: genetic heterogeneity and evidence for a second locus at 15q24[J]. The American Journal of Human Genetics, 1998, 63(4):1108-1116.
- [13] Hu J. Comparison of Different Features and Classifiers for Driver Fatigue Detection Based on a Single EEG Channel[J]. Comput Math Methods Med, 2017, 2017(3):5109530.
- [14] Wang H, Zhang C, Shi T, et al. Real-Time EEG-Based Detection of Fatigue Driving Danger for Accident Prediction[J]. International Journal of Neural Systems, 2015, 25(2):498-369.
- [15] Gharagozlou F, Saraji G N, Mazloumi A, et al. Detecting Driver Mental Fatigue Based on EEG Alpha Power Changes during Simulated Driving[J]. Iranian Journal of Public Health, 2015, 44(12):1693-1700.
- [16] Nguyen T, Ahn S, Jang H, et al. Utilization of a combined EEG/NIRS system to predict driver drowsiness[J]. Scientific Reports, 2017, 7(3):43933.
- [17] Silveira T L T D, Kozakevicius A J, Rodrigues C R. Automated drowsiness detection through wavelet packet analysis of a single EEG channel[J]. Expert Systems with Applications, 2016, 55(8):559-565.

- [18] Rothkrantz L. Automatic detection system of micro sleeps of car drivers based on EEG analysis[C]// International Conference on Computer Systems and Technologies. ACM, 2016:214-221.
- [19] 王福旺, 王宏, 罗旭. 基于 EEG 与 EOG 信号的疲劳驾驶状态综合分析[J]. 东北大学学报(自然科学版), 2014, 35(2):175-178.
- [20] Usoro J, Kenyon L, Farris J, et al. Changes in EEG spectrum and mutual information during power mobility training[C]// Biomedical Conference. IEEE, 2017:1-1.
- [21] Huo X Q, Zheng W L, Lu B L. Driving fatigue detection with fusion of EEG and forehead EOG[C]// International Joint Conference on Neural Networks. IEEE, 2016:897-904.
- [22] Němcová A, Janoušek O, Vitek M, et al. Testing of features for fatigue detection in EOG.[J]. Bio-medical materials and engineering, 2017, 28(4):379.
- [23] 吕钊, 吴小培, 张超, 等. 基于 EOG 的安全辅助驾驶系统算法设计与实现[J]. 通信学报, 2016, 37(7): 87-95.
- [24] Wang C Y, Yu S C, Lin Y C, et al. Fatigue detection system based on indirect-contact ECG measurement[C]// International Conference on Advanced Robotics and Intelligent Systems. IEEE, 2017.
- [25] Chen P Y, Chang M J, Tu K C, et al. Study of Using Fourier Transform to Capture the ECG Signals between Awakeness and Dozing[C]// International Symposium on Computer, Consumer and Control. IEEE, 2016:1055-1058.
- [26] 周云鹏, 朱青, 王耀南, 等. 面部多特征融合的驾驶员疲劳检测方法[J]. 电子测量与仪器学报, 2014, 28(10):1140-1148.
- [27] Karchani M, Mazloumi A, Saraji G N, et al. Presenting a model for dynamic facial expression changes in detecting drivers' drowsiness[J]. Electronic Physician, 2015, 7(2):1073.
- [28] Acioğlu A, Erçelebi E. Real time eye detection algorithm for PERCLOS calculation[C]// Signal Processing and Communication Application Conference. IEEE, 2016:1641-1644.
- [29] 赵晓琳, 王世刚, 姜秀红, 等. 基于人眼状态的驾驶员疲劳检测[J]. 吉林大学学报(信息科学版), 2015, 33(4):449-453.
- [30] 付锐, 程文冬, 张名芳, 等. 基于动态匹配模型的驾驶人嘴部行为识别与分级预警[J]. 汽车工程, 2015, 37(9):1095-1102.
- [31] Ibrahim M M, Soraghan J J, Petropoulakis L, et al. Yawn analysis with mouth occlusion detection[J]. Biomedical Signal Processing & Control, 2015, 18(8):360-369.
- [32] Eskandarian A, Mortazavi A. Evaluation of a Smart Algorithm for Commercial Vehicle Driver Drowsiness Detection[C]// Intelligent Vehicles Symposium. IEEE, 2007:553-559.
- [33] 孙香梅. 基于车辆运行轨迹的疲劳驾驶检测研究[D]. 长沙理工大学, 2012.
- [34] Zhao H, Guo X, Wang M, et al. Analyze EEG signals with extreme learning machine based on PMIS feature selection[J]. International Journal of Machine Learning & Cybernetics, 2015, 9(6):1-7.

- [35] Chai, Naik R, Ling G R, et al. Channels Selection using Independent Component Analysis and Scalp Map Projection for EEG-based Driver Fatigue Classification[C]// International Conference of the IEEE Engineering in Medicine & Biology Society. IEEE, 2017.
- [36] Ozmen N G, Gumusel L, Yang Y. A Biologically Inspired Approach to Frequency Domain Feature Extraction for EEG Classification[J]. Computational & Mathematical Methods in Medicine, 2018, 2018(1):1-10.
- [37] Dkhil M B, Wali A, Alimi A M. Drowsy driver detection by EEG analysis using Fast Fourier Transform[C]// International Conference on Intelligent Systems Design and Applications. IEEE, 2016:313-318.
- [38] Wali M K, Murugappan M, Ahmmad B. Wavelet Packet Transform Based Driver Distraction Level Classification Using EEG[J]. Mathematical Problems in Engineering 2013, 2013(3):841-860.
- [39] Ghorbanian P, Devilbiss D M, Simon A J, et al. Discrete wavelet transform EEG features of Alzheimer'S disease in activated states[C]// International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE, 2012:2937-2940.
- [40] Learned R E, Willsky A S. A Wavelet Packet Approach to Transient Signal Classification[J]. Applied & Computational Harmonic Analysis, 1995, 2(3):265-278.
- [41] Alickovic E, Kevric J, Subasi A. Performance evaluation of empirical mode decomposition, discrete wavelet transform, and wavelet packed decomposition for automated epileptic seizure detection and prediction[J]. Biomedical Signal Processing & Control, 2018, 39(1):94-102.
- [42] Wan P, Wen J, Wu C. A discriminating method of driving anger based on sample entropy of EEG and BVP[C]// International Conference on Transportation Information and Safety. IEEE, 2015:156-161.
- [43] Mu Z, Hu J, Yin J. Driving Fatigue Detecting Based on EEG Signals of Forehead Area[J]. International Journal of Pattern Recognition & Artificial Intelligence, 2016, 31(05):40-44.
- [44] Hu J, Wang P. Noise Robustness Analysis of Performance for EEG-Based Driver Fatigue Detection Using Different Entropy Feature Sets[J]. Entropy, 2017, 19(8):385-414.
- [45] Min J, Wang P, Hu J. Driver fatigue detection through multiple entropy fusion analysis in an EEG-based system.[J]. Plos One, 2017, 12(12):e0188756.
- [46] 王春方, 张力新, 张希,等. 抑郁症自发脑电信号特异性研究进展[J]. 中国生物医学工程学报, 2014, 33(1):86-92.
- [47] 黄日辉, 李霆, 阜艳,等. 诱发脑电提取方法的研究进展[J]. 现代电子技术, 2008, 31(22):139-141.
- [48] 王怡玲, 覃玉荣, 郭湛超. 基于不同闪烁频率光刺激的脑电压变化研究[J]. 中国医学物理学杂志, 2014, 31(5):5184-5187.
- [49] 陈建. 脑部信号采集系统的计算机视觉标定方法[D]. 浙江工业大学, 2014.
- [50] 梅冬梅. 具体情绪到元情绪的 ERP 研究[D]. 信阳师范学院, 2014.

- [51] Huang N E, Shen Z, Long S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis[J]. Proceedings of the Royal Society of London A, 1998, 454(1971):903-995.
- [52] Pachori R B, Patidar S. Epileptic seizure classification in EEG signals using second-order difference plot of intrinsic mode functions[J]. Comput Methods Programs Biomed, 2014, 113(2):494-502.
- [53] Stéphan J M, Misguich G, Pasquier V. Phase transition in the Rényi-Shannon entropy of Luttinger liquids[J]. Physical Review B Condensed Matter, 2017, 84(19):1160-1164.
- [54] Núñez J A, Cincotta P M, Wachlin F C. Information entropy[J]. Celestial Mechanics & Dynamical Astronomy, 1996, 64(1-2):43-53.
- [55] Liu T, Yao W, Wu M, et al. Multiscale permutation entropy analysis of electrocardiogram[J]. Physica A: Statistical Mechanics and its Applications, 2017, 471: 492-498.
- [56] RICHMAN J S, LAKE D E, MOORMAN J R. Sample entropy[J]. Methods in enzymology, 2004, 384(8): 172-184.
- [57] 高军峰, 司慧芳, 余彬, 等. 基于脑电样本熵的测谎分析[J]. 电子学报, 2017, 2017(8):1836-1841.
- [58] Chen W, Wang Z, Xie H, et al. Characterization of surface EMG signal based on fuzzy entropy[J]. IEEE Transactions on Neural Systems & Rehabilitation Engineering, 2007, 15(2):266.
- [59] L. Breiman, Random forests, Machine Learning 45 (1) (2001) 5-32.
- [60] Fraiwan L, Lweesy K, Khasawneh N, et al. Automated sleep stage identification system based on time-frequency analysis of a single EEG channel and random forest classifier[J]. Computer Methods & Programs in Biomedicine, 2012, 108(1):10-19.
- [61] Khondoker M, Dobson R, Skirrow C, et al. A comparison of machine learning methods for classification using simulation with multiple real data examples from mental health studies[J]. Statistical Methods in Medical Research, 2016, 25(5):1804.
- [62] Brinkmann B H, Patterson E E, Vite C, et al. Forecasting Seizures Using Intracranial EEG Measures and SVM in Naturally Occurring Canine Epilepsy[J]. Plos One, 2015, 10(8):e0133900.
- [63] Bousseta R, Tayeb S, Ouakouak I E, et al. EEG efficient classification of imagined hand movement using RBF kernel SVM[C]// International Conference on Intelligent Systems: Theories and Applications. IEEE, 2016:1-6.
- [64] Abdulhay E, Elamran V, Chandrasekar M, et al. Automated diagnosis of Epilepsy from EEG signals using Ensemble Learning approach[J]. Pattern Recognition Letters, 2017, 2017(6):19:53.
- [65] Tahernezhad-Javazm F, Azimirad V, Shoaran M. A review and experimental study on application of classifiers and evolutionary algorithms in EEG based brain-machine interface systems[J]. Journal of Neural Engineering, 2017, 2017(8):19:53.

- [66] Wang G, Deng Z, Choi K S. Detection of Epilepsy with Electroencephalogram using Rule-based Classifiers[J]. *Neurocomputing*, 2016, 228(3):283-290.
- [67] Rout N. Analysis and Classification Technique Based On ANN for EEG Signals[J]. *International Journal of Computer Science & Information Technolo*, 2014, 5(4):5103-5105.
- [68] Zhang C, Wang H, Fu R. Automated Detection of Driver Fatigue Based on Entropy and Complexity Measures[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2014, 15(1):168-177.
- [69] 饶国强, 冯辅周, 司爱威, 等. 排列熵算法参数的优化确定方法研究[J]. *振动与冲击*, 2014, 33(1):188-193.
- [70] Wu S D, Wu C W, Lee K Y, et al. Modified multiscale entropy for short-term time series analysis[J]. *Physica A Statistical Mechanics & Its Applications*, 2013, 392(23):5865-5873.
- [71] 张栋. Lempel-Ziv 复杂度的尺度划分方法的研究及应用[D]. 太原理工大学, 2013.
- [72] Hu J, Mu Z. EEG authentication system based on auto-regression coefficients[C]// *International Conference on Intelligent Systems and Control*. IEEE, 2016:1-5.
- [73] Jiménez-Valverde A. Insights into the area under the ROC curve (AUC) as a discrimination measure in species distribution modelling[J]. 2011, 21(4):498-507.
- [74] 谢丽潇, 邓赵红, 史荧中, 等. 面向癫痫 EEG 自适应识别的迁移径向基神经网络[J]. *计算机科学与探索*, 2016, 10(12):1729-1736.

攻读学位期间的研究成果

已发表论文:

1. 刘超, 李志鹏, 余宇婷, 等. 基于 Flex 和 WebGIS 的地面气象观测数据分析服务系统[J]. 南昌大学学报(工科版), 2017(4):386-392.